



UNIVERSIDADE FEDERAL DA BAHIA - UFBA
INSTITUTO DE MATEMÁTICA - IM
TRABALHO DE CONCLUSÃO DE CURSO - TCC
MONOGRAFIA



METAESTABILIDADE

JOÃO DELGADO

Salvador - Bahia
27 de março de 2026

METAESTABILIDADE

JOÃO VICTOR FONSECA DELGADO DA SILVA

Orientador: Prof. Dr. Tertuliano Franco
Santos Franco.

Salvador - Bahia
27 de março de 2026

Agradecimentos

“Mede o que é mensurável e torna mensurável o que não o é”.

Galileu Galilei (1564-1642)

Resumo

O objetivo desta dissertação é estudar e apresentar alguns resultados sobre
.....

Palavras-chave: sistemas de partículas, cadeias de Markov.

Abstract

The objective of this dissertation is .

Keywords: random graphs, phase transition.

Conteúdo

Introdução	1
1 Noções básicas de medida e probabilidade	2
1.1 Cadeia de Markov	6
1.2 Função de representação aleatória	7
1.3 Passeio aleatório em grafos	9
1.4 Distribuição estacionária	10
2 Metaestabilidade para o passeio aleatório no hipercubo	11
2.1 Tipos de passeios aleatórios homogêneos:	11
2.1.1 Passeio homogêneo preguiçoso $\sigma(t)$	11
2.1.2 Passeio homogêneo não preguiçoso $\xi(t)$	12
3 Abordagem Potencial para Metaestabilidade	19
3.1 Apêndice A	21
Referências Bibliográficas	23
Índice Remissivo	24

Lista de Figuras

3.1	Malha $\Lambda_N = \{0, \dots, N\}^d$ com um elemento de E_N destacado por azul.	19
3.2	Um caminhar aleatório com dois estados	20
3.3	Acoplamento de dois caminhar aleatório com N fixo	22

Introdução

Capítulo 1

Noções básicas de medida e probabilidade

Nesse capítulo vamos falar das noções iniciais de probabilidade para que possamos compreender os processos de metaestabilidade. Inicialmente falaremos da construção da σ -álgebra e as consequências de imbuir esse objeto com uma medida, assim seguindo para a construção da medida de probabilidade. Em sequência, falamos um sobre as propriedades das cadeias de Markov, que são um dos objetos mais importantes quando falamos de metaestabilidade.

Definição 1.1. *Uma álgebra de um conjunto Ω é uma classe $\mathcal{F}$ de subconjuntos de Ω tal que:*

- i. $\Omega \in \mathcal{F}$,*
- ii. $A \in \mathcal{F}$ implica que $A^c \in \mathcal{F}$,*
- iii. $A, B \in \mathcal{F}$ implica que $A \cup B \in \mathcal{F}$.*

Uma álgebra é uma classe que se pode realizar operações elementares de conjuntos, o que é característica muito boa, pois como funções trabalham com conjunto e, sem esses objetos, ficamos muito restritos ou até de mãos atadas ao desenvolver uma teoria. Contudo, a álgebra ainda não é uma estrutura adequada para trabalhar com probabilidade, pois, apesar das uniões de dois elementos da álgebra estarem na álgebra, a união infinitesimal desses elementos pode não estar no conjunto. Logo, precisamos de uma estrutura que seja fechada para uniões enumeráveis.

Definição 1.2. *Uma σ -álgebra é uma álgebra fechada por uniões enumeráveis, ou seja,*

- iv. $A_j \in \mathcal{F}$ tal que $j = 1, 2, \dots$ implica que $\bigcup_{j=1}^{\infty} A_j \in \mathcal{F}$.*

Exemplo 1.1. Um exemplo básico de uma σ -álgebra é o que corresponde ao lançamento de um dado de 6 lados honesto. O nosso conjunto de estudo seria os lados do dado, $D = \{1, 2, 3, 4, 5, 6\}$ e nossa σ -álgebra é $\mathcal{S} = \mathcal{P}(D)$, as partes de D .

Definição 1.3 (σ -álgebra gerada por uma classe de subconjuntos). Seja $\mathcal{E}$ uma classe de subconjuntos de Ω . Então definamos $\sigma(\mathcal{E})$ como a única σ -álgebra gerada por $\mathcal{E}$ que satisfaz:

- i. $\sigma(\mathcal{E})$ é σ -álgebra,
- ii. $\mathcal{E} \subseteq \sigma(\mathcal{E})$,
- iii. Se $\mathcal{S}$ é σ -álgebra $\mathcal{E} \subseteq \mathcal{S}$, então implica que $\sigma(\mathcal{E}) \subseteq \mathcal{S}$.

Exemplo 1.2. Ainda pensando no dado, tomemos uma classe de conjuntos $\mathcal{E} = \{\{1, 2\}\}$. Podemos criar uma σ -álgebra, $\sigma(\mathcal{E})$, adicionando $D, \{1, 2\}, \emptyset, \{3, 4, 5, 6\}$ em $\sigma(\mathcal{E})$, logo temos $\sigma(\mathcal{E}) = \{D, \emptyset, \{1, 2\}, \{3, 4, 5, 6\}\}$. Perceba que as uniões dois-a-dois são fechadas, então $\sigma(\mathcal{E})$ é σ -álgebra.

Criado o nosso espaço onde vamos estudar (espaços mensuráveis), podemos começar a elaborar a ideia de probabilidade.

Definição 1.4. Uma medida em um espaço mensurável, $(\Omega, \mathcal{S})$, é uma função $\mu : \mathcal{S} \rightarrow [0, +\infty]$ que satisfaz:

- i. $\mu(\emptyset) = 0$,
- ii. $\mu\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mu(A_i)$ para todo $A_i \in \mathcal{S}$ dois a dois disjuntos.

A tripla $(\Omega, \mathcal{S}, \mu)$ denomina-se espaço de medida.

Observe que isso inclui somas finitas, pois podemos considerar os A_n tal qual para todo $n > n_0$ é igual a $\emptyset$. Um exemplo importante de medida é a delta de Dirac:

Exemplo 1.3. Seja Ω um conjunto e consideremos $\mathcal{P}(\Omega)$, as partes de Ω , então dado um $p \in \Omega$, seja a função $\delta_p : \mathcal{P}(\Omega) \rightarrow [0, +\infty]$:

$$\delta_p(A) = \begin{cases} 1, & \text{se } p \in A; \\ 0, & \text{c.c.} \end{cases}$$

Vamos agora ver algumas propriedades das medidas que não são nenhuma surpresa, mas que precisamos formular.

Teorema 1.1. Seja $(\Omega, \mathcal{S}, \mu)$ um espaço de medida e $A, B, A_1, A_2, \dots \in \mathcal{S}$.

1. $\mu(A^c) = \mu(\Omega) - \mu(A)$,
2. Se $A \subseteq B$, então vale que $\mu(A) \leq \mu(B)$ e $\mu(B \setminus A) = \mu(B) - \mu(A)$,
3. $\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B)$,
4. $\mu\left(\bigcup_{n=1}^{\infty} (A_n)\right) \leq \sum_{n=1}^{\infty} \mu(A_n)$,
5. Se $\mu(A_n) < \infty$, $A_n \uparrow A$ ou $A_n \downarrow A$, então $\mu(A_n) \rightarrow \mu(A)$.

Demonstração. 1. Como $\Omega = A \cup A^c$, temos que $\mu(\Omega) = \mu(A \cup A^c) = \mu(A) + \mu(A^c)$.

2. Como $A \subseteq B$, então $B = A \cup B \setminus A \Rightarrow \mu(B) = \mu(A \cup B \setminus A) = \mu(A) + \mu(B \setminus A) \Rightarrow \mu(B \setminus A) = \mu(B) - \mu(A)$.

3. Usando o item (ii) temos que $\mu(A \cup B) = \mu(A) + \mu(B \setminus A)$. Como $\mu(B) = \mu(B \setminus A) + \mu(A \cap B)$, então $\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B)$.

4. A partir de uma sequência de A_n podemos criar uma sequência disjunta. Seja $B_1 = A_1$, $B_2 = A_2 \setminus A_1$, $B_3 = A_3 \setminus (A_2 \cup A_1)$, etc. Ou seja, $B_n = A_n \setminus (\bigcup_{j=1}^{n-1} A_j)$, perceba que B_n é uma sequência de conjuntos disjunta. Assim $\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \mu\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} \mu(B_n) \leq \sum_{n=1}^{\infty} \mu(A_n)$.

5. Suponhamos que $A_n \uparrow A$, então $A_n \subset A_{n+1}$. Como é uma sequência de conjuntos arbitrário, a fim de obter melhor controle, podemos criar uma sequência B_n de conjuntos disjunta tal que $\bigcup_n^{\infty} B_n = \bigcup_n^{\infty} A_n$, definindo $B_n = A_n \setminus A_{n-1}$ sendo $A_0 = \emptyset$.
 Fixe um $k \in \mathbb{N}$ e $i \geq 1$. Daí, $\bigcup_i^k B_i = \bigcup_i^k (A_i \setminus A_{i-1})$ nos leva a

$$\begin{aligned} \mu\left(\bigcup_i^k B_i\right) &= \mu\left(\bigcup_i^k (A_i \setminus A_{i-1})\right), \\ &= \sum_i^k \mu(A_i \setminus A_{i-1}), \\ &= \sum_i^k (\mu(A_i) - \mu(A_{i-1})). \end{aligned}$$

Como o lado direito da equação é uma soma telescópica, temos que $\mu(\bigcup_i^k B_i) = \mu(A_k) - \mu(A_0)$. Logo,

$$\begin{aligned} \lim_{k \rightarrow \infty} \mu \left(\bigcup_i^k B_i \right) &= \lim_{k \rightarrow \infty} \mu(A_k), \\ \Rightarrow \mu \left(\bigcup_i^\infty B_i \right) &= \mu \left(\bigcup_i^\infty A_i \right) = \mu(A). \end{aligned}$$

Para provar $A_n \downarrow A$, podemos utilizar o que acabamos de provar. Tome a sequência $A_n^c \uparrow A^c$ e lembrando que $P(A_n) = 1 - P(A_n^c)$, então se $n \rightarrow \infty$ temos que $\lim_{n \rightarrow \infty} P(A_n) = 1 - P(A^c)$. □

Agora que entendemos um pouco sobre medidas e σ -álgebras, podemos começar a adentrar no assunto de probabilidade. Contudo o que seria uma probabilidade? É intuitivo pensar que probabilidade satisfaça as definições de medida, pois com esse objeto temos o intuito de medir quão provável um evento pode ocorrer.

Definição 1.5. *Seja $(\Omega, \mathcal{S}, \mu)$ um espaço de medida. Se $\mu : \mathcal{S} \rightarrow \mathbb{R}$ é uma função que satisfaz:*

- i. $\mu(\Omega) = 1$,
- ii. $\mu \left(\bigcup_{i=1}^\infty A_i \right) = \sum_{i=1}^\infty \mu(A_i)$ para todo $A_i \in \mathcal{S}$ dois a dois disjuntos.

Então μ é uma medida de probabilidade. A tripla $(\Omega, \mathcal{S}, \mu)$ denomina-se espaço de probabilidade.

Perceba que pela afirmação 1, temos que $\mu(\Omega) = 1 - \mu(\emptyset) = 1$. Logo, essa definição para probabilidade μ , nos diz que também é medida, assim tudo que vimos para medida vale para probabilidade.

Seja $(\Omega, \mathcal{S}, \mu)$ um espaço de probabilidade. Tome dois eventos $A, B \in \mathcal{S}$ tais que $\mu(A) = a$ e $\mu(B) = b$. Qual é a probabilidade do evento acontecer A se sabemos que o evento B acontece?

Definição 1.6. *Seja $(\Omega, \mathcal{S}, \mu)$ um espaço de probabilidade e $A, B \in \mathcal{S}$ tal que $\mu(B) > 0$. Uma probabilidade condicional de A dado B é $\mathbb{P} : \mathcal{S} \rightarrow \mathbb{R}$*

$$\mathbb{P}(A|B) = \frac{\mu(A \cap B)}{\mu(B)}.$$

Quando $\mu(B) = 0$, então definimos $\mathbb{P}(A|B) = \mathbb{P}(A)$.

A probabilidade condicional diferente da noção usual de probabilidade, contextualiza as chances de um evento acontecer. Perceba que quando $\mathbb{P}(B) > 0$, a primeira nada mais é do que relativização da probabilidade do evento A para o evento B . Veja que estamos falando de eventos, elementos da σ -álgebra e não qualquer subconjunto de Ω .

Teorema 1.2 (Regra do produto). *Em $(\Omega, \mathcal{S}, \mu)$. Dados os eventos $A_1, A_2, \dots, A_n \in \mathcal{S}$,*

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1)\mathbb{P}(A_2|A_1)\mathbb{P}(A_3|A_1 \cap A_2) \dots \mathbb{P}\left(A_n \left| \bigcap_{i=1}^{n-1} A_i\right.\right).$$

Definição 1.7 (Eventos independentes). *Seja $A, B \in \mathcal{S}$ são independentes se*

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Logo, se a sequência de eventos A_i são independentes, então $\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n \mathbb{P}(A_i)$, pois $\mathbb{P}(A_j|A_i) = \mathbb{P}(A_j)$.

1.1 Cadeia de Markov

Definição 1.8 (Cadeia de Markov finita). *Seja $(\Omega, \sigma\{\Omega\}, \mathbb{P})$ um espaço de probabilidade e $(X_1, X_2, X_3, \dots)$ uma sequência aleatória de variáveis que satisfaz, juntamente com uma matriz de transição $\mathbb{P}$, a propriedade de Markov, definida da seguinte forma: Se para $\forall x, y \in \Omega$, para todo $t \geq 1$, e para todo evento $H_{t-1} = \bigcap_{s=0}^{t-1} \{X_s = x_s\}$ satisfaz $\mathbb{P}(H_{t-1} \cap \{X_t = x\}) > 0$, nos temos que*

$$\mathbb{P}\left\{X_{t+1} = y | H_{t-1} \cap \{X_t = x\}\right\} = \mathbb{P}\left\{X_{t+1} = y | \{X_t = x\}\right\}.$$

Em termos mais amigáveis, a probabilidade de a sequência chegar a um determinado estado depende apenas do estado anterior, podemos pensar nisso como uma sequência que apresenta perda de memória. Como estamos trabalhando com probabilidade, a soma das chances de transição de um estado para todos os outros deve ser igual a 1. Por isso, a nossa matriz de transição precisa ser estocástica.

Definição 1.9 (Matriz estocástica). *Denominamos P de matriz estocástica, se as suas entradas são não-negativas e a soma de elementos de cada coluna da matriz é igual a um, isso é, $\sum_{j \in |\Omega|} P_{ij} = \mathbb{P}(x, \cdot) = 1 \forall x \in \Omega$.*

Em muitos casos gostaríamos de trabalhar com distribuições de pontos diferentes do espaço, $\mathbb{P}(x, \cdot), \mathbb{P}(y, \cdot)$, então para facilitar a compreensão, vamos utilizar a notação $\mathbb{E}_x, \mathbb{P}_x$.

$$\mathbb{E}_x(f(X_1)) = \sum_y f(y) \mathbb{P}_x(X_1 = y) = \sum_y f(y) \mathbb{P}(x, y) = \mathbb{P}f(X).$$

tal que f é uma função. Notação: $\mathbb{P}_x(X_t = y) = (\delta_x \mathbb{P}^t)(y) = \mathbb{P}^t(x, y)$.

1.2 Função de representação aleatória

Definição 1.10 (Função de representação aleatória de uma matriz P em um espaço de estados Ω). *A função f é uma representação aleatória se $f : \Omega \times \Lambda \rightarrow \Lambda$, onde Λ são os valores da variável aleatória Z definida em Ω , satisfaz*

$$\mathbb{P}(f(x, Z(x)) = Y) = \mathbb{P}(x, y).$$

A função de representação é uma ótima ferramenta para substituírmos a matriz de transição quando temos uma quantidade extensa de estados tornando as operações laboriosas. Seja uma sequência de variáveis $(Z_n)_n$ iid's com mesma distribuição de Z e X_0 com distribuição μ , podemos definir uma sequência de variáveis aleatórias $(X_n)_n$ como

$$X_n = f(X_{n-1}, Z_n) \quad n \geq 1,$$

tal que essa sequência é uma cadeia de Markov com uma matriz de transição P com distribuição μ .

Proposição 1.1. *Toda matriz de transição em um espaço de Markov finito tem uma função de representação aleatória.*

Demonstração. Seja P uma matriz de transição de um espaço de Markov com o espaço de estados $\Omega = \{x_1, x_2, \dots, x_n\}$ e seja $\Lambda = [0, 1]$, onde as variáveis aleatórias auxiliares $Z, Z_1, Z_2, \dots$ são iid's nesse intervalo. Definamos $F_{ij} = \sum_{k=1}^j \mathbb{P}(x_i, x(k))$, então podemos definir f como $f(x_i, Z) := x_j$ quando $F_{i,j-1} < Z < F_{i,j}$. Portanto,

$$\mathbb{P}\{f(x_i, Z) = x_j\} = \mathbb{P}\{F_{i,j-1} < Z < F_{i,j}\} = \mathbb{P}(x_i, x_j).$$

□

Veremos em seguidas algumas propriedades dessas cadeias de Markov que nos permite extrair algumas informações.

Definição 1.11 (Irredutível). *Seja P uma cadeia, se para todo $x, y \in \Omega$, existe um inteiro t tal que $\mathbb{P}^t(x, y) > 0$.*

Definição 1.12 (Período de x). *Definamos o conjunto $T(x) = \{t \geq 1 : \mathbb{P}^t(x, x) > 0\}$. O período de x é o maior divisor comum (mdc de $T(x)$).*

Proposição 1.2. *Se P é irredutível, então $\text{mdc}(T(x)) = \text{mdc}(T(y))$ para $x, y \in \Omega$.*

Demonstração. Seja $k \in T(x)$. Sabemos que existe r e l tal que $\mathbb{P}^r(x, y) > 0$ e $\mathbb{P}^l(x, y) > 0$. Seja $m = r + l$, é direto ver que $m \in T(x) \cap T(y)$. Provaremos que $k + m \in T(y)$,

$$\begin{aligned}\mathbb{P}^{k+m}(x, x) &= \mathbb{P}^k(x, x)\mathbb{P}^r(x, y)\mathbb{P}^l(y, x) \\ &= \mathbb{P}^l(y, x)\mathbb{P}^k(x, x)\mathbb{P}^r(x, y) \\ &= \mathbb{P}^{l+k+r}(y, y) = \mathbb{P}^{m+k}(y, y)\end{aligned}$$

Então $k + m \in T(y)$, então $k \in T(y) - m \Rightarrow T(x) \subset T(y) - m$. Portanto, $\frac{\text{mdc}(T(y))}{T(x)}$, consequentemente $\text{mdc}(T(y)) \leq \text{mdc}(T(x))$. Para $\text{mdc}(T(x)) \leq \text{mdc}(T(y))$ é análogo. Portanto, $\text{mdc}(T(y)) = \text{mdc}(T(x))$. $\square$

Definição 1.13 (Aperiódico). *Se em uma cadeia o $\text{mdc}(T(x)) \forall x \in \Omega$ é 1, então denominamos aperiódico. Se a cadeia não é aperiódico, então é periódico.*

Proposição 1.3. *Se P é irredutível, então existe um inteiro r tal que $\mathbb{P}^r(x, y) > 0$ para $\forall x, y \in \Omega$.*

Demonstração. Antes de provar essa proposição, iremos demonstrar um lema que nos garantirá que a partir de um inteiro vai ser possível o retorno de um $x \in \Omega$.

Lema 1.1. *Seja $S \subset \mathbb{Z}^+$ tal qual é fechado por adição e de $\text{mdc}(S) = 1$, então existe $m_s \in \mathbb{Z}^+$ tal que para todos $m \geq m_s$ pode ser escrito como combinação linear de elementos de S .*

Demonstração. Como o $\text{mdc}(S) = 1$, podemos aplicar o Teorema de Bézout. Seja $a, b \in S, \exists x, y \in \mathbb{Z}, ax + by = 1$. O caso de $x, y \geq 0$, então está feito. O caso de $x, y < 0$, não ocorre, pois $a, b \leq 0$. Então só nos resta o caso de $x > 0$ e $y < 0$ ou contrário. Suponhamos que $y > 0$ e $x < 0$, e seja $k \in \mathbb{Z}^+$, logo $\exists r, q \in \mathbb{Z}^+(k = aq + r \wedge a \geq r \geq q)$.

$$\begin{aligned}1 &= xa + yb \\ r &= rxa + ryb, \\ k &= aq + r = rxa + aq + ryb \\ k &= (rx + q)a + ryb.\end{aligned}$$

Como $y > 0$ e $r \leq 0$, então só precisamos verificar $xr + q$. Lembrando que $x < 0$, logo $(-x) > 0$.

$$xr + q > 0 \Leftrightarrow q > (-x)r.$$

Como $a > r$, então $q > (-x)a$. □

Agora, podemos provar a proposição 1.3. Vamos provar que $\forall x \in \Omega$, $T(x)$ é fechado por adição. Seja $a, b \in T(x)$, $\mathbb{P}^{a+b}(x, x) = \mathbb{P}^a(x, x)\mathbb{P}^b(x, x) > 0$, então $a + b \in T(x)$. Logo, pelo lema anterior, sabemos que existe t_x tal que $t \geq t_x$, $\mathbb{P}^{t_x}(x, x) > 0$. Como sistema é irredutível, então existe um inteiro $k = k(x, y)$ tal que $\mathbb{P}^k(x, y) > 0$. Logo, fixado x , seja $t = t_x + r(x, y)$,

$$\mathbb{P}^t(x, y) \geq \mathbb{P}^{t_x}(x, x)\mathbb{P}^{r(x, y)}(x, y) > 0.$$

□

1.3 Passeio aleatório em grafos

Um grafo $G = (V, E)$ consiste em um conjunto de vértice V e um conjunto de aresta E , onde $E \subset \{\{x, y\} : x, y \in V \text{ e } x \neq y\}$ e V é o conjunto de pontos tal que para cada par de ponto ligados por um linha. Denotando $\{x, y\} \in E$ como $x \sim y$, chamamos y de vizinhança de x . E o total de vizinhança de x como o grau de x , ou seja, $|\{x \sim y : y \in V\}| = \deg(x)$.


Como um exemplo inicial, podemos definir um grafo e criar uma função de probabilidade a partir da vizinhança de um ponto, tornando a escolha de um vértice pular para outro, ser uniforme.

$$\mathbb{P}(x, y) = \begin{cases} \frac{1}{\deg(x)}; & \text{se } x \sim y, \\ 0; & \text{c.c.} \end{cases}$$

Exemplo 1.4. Seja G um grafo de 2 vértices. Então temos uma matriz de transição

$$P = \begin{pmatrix} \frac{1}{2} & 1 \\ \frac{1}{2} & 0 \end{pmatrix}.$$

Ou seja,



1.4 Distribuição estacionária

Em caminhadas aleatórias podemos andar tanto e acabar tendendo a algum lugar. Assim, se verificarmos que a distribuição de uma caminhada aleatória está tendendo para algum lugar, então dizemos que ela é estacionária.

Definição 1.14. *Seja P uma matriz de transição em grafo G . Definimos como uma distribuição estacionária, quando uma medida de probabilidade π satisfaz*

$$\pi = \pi P.$$

De forma equivalente podemos reescrever nossa definição como

$$\pi(y) = \sum_{x \in V} \pi(x) P(x, y).$$

Exemplo 1.5. *Utilizando o simples andar aleatório sobre um grafo $G = (V, E)$. Para qualquer $y \in V$*

$$\sum_{x \in V} \deg(x) P(x, y) = \sum_{x \sim y} \frac{\deg(x)}{\deg(x)} = \deg(y)$$

Utilizando como normalizador $\sum_{y \in V} \deg(y) = 2|E|$, podemos dizer que a medida de probabilidade

$$\pi(y) = \frac{\deg(y)}{2|E|} \quad \forall y \in V$$

é uma distribuição estacionária.

Capítulo 2

Metaestabilidade para o passeio aleatório no hipercubo

Chamaremos $H_N = \{-1, +1\}^N$ um conjunto de configurações de N spins (as entradas) com possíveis valores $\{+1, -1\}$. Os elementos do H_N são representados por ν e ζ , ou seja, $\nu = (\nu_1, \dots, \nu_N)$ e $\zeta = (\zeta_1, \dots, \zeta_N)$ onde ζ_i e $\nu_i \in \{+1, -1\}, \forall i \in \{1, \dots, N\}$. Seja $\nu \in H_N$, o valor da troca no spin j de ν é denotado por ν^j .

$$(\nu^j)_i = \begin{cases} \nu_i & , \text{se } i \neq j; \\ -\nu_j & , \text{se } i = j. \end{cases}$$

2.1 Tipos de passeios aleatórios homogêneos:

2.1.1 Passeio homogêneo preguiçoso $\sigma(t)$

Seja $\nu \in H_N$ e $\sigma(0) = \nu$, $\sigma(t)$ é uma evolução estocástica em relação a um tempo discreto, onde para cada t escolhemos $i \in \{1, \dots, N\}$ com probabilidade $\frac{1}{N}$ e escolheremos em seguida o spin $\sigma_i = +1$ com probabilidade $\frac{1}{2}$. Podemos interpretar o passeio homogêneo como a sequência de duas variáveis aleatórias $I(t)$ e $U(t)$, definidas em $(\Omega_N, \mathcal{F}_N, \mathbb{P}_N)$, sendo $I(t) \in \{1, \dots, N\}$ independente e $\forall k \in \{1, \dots, N\}; \mathbb{P}_N(I(t) = k) = \frac{1}{N}$ e $U(t) \in [0, 1]$ independente e $\forall u \in [0, 1]; \mathbb{P}_N(U(t) < u) = u$, ou seja, identicamente distribuída uniformemente em $[0, 1]$.

Assim,

$$(\sigma_j(t)) = \begin{cases} \sigma(t-1) & , \text{se } I(t) \neq j; \\ +1 & , \text{se } I(t) = j; U(t) < \frac{1}{2}; \\ -1 & , \text{se } I(t) = j; U(t) \geq \frac{1}{2}. \end{cases}$$

2.1.2 Passeio homogêneo não preguiçoso $\xi(t)$

Seja $\xi(0) = \nu \in H_N$ e $\xi(t)$ um passeio aleatório no H_N definido em $(\Omega_0, \mathcal{F}_0, \mathbb{P}_0)$ com probabilidade de transição $\mathbb{P}(\xi(t+1) = \nu^i | \xi(t) = \nu) = \frac{1}{N}$ para todo $k \geq 1$, $i \in \{1, \dots, N\}$. Perceba que $\mathbb{P}(\xi(t+1) = \nu | \xi(t) = \nu) = 0$, pois $\sum_i \mathbb{P}(\xi(t+1) = \nu^i | \xi(t) = \nu) = \left(N \cdot \frac{1}{N}\right) = 1$, ou seja, a probabilidade dele mudar alguma entrada/spin 100%.

Agora vamos introduzir algumas notações básicas para não ocorrer nenhum tipo de ambiguidade.

Notações

σ^- é o passeio homogêneo com configuração inicial $\sigma^-(0) = (-1, \dots, -1)$.

σ^+ é o passeio homogêneo com configuração inicial $\sigma^+(0) = (+1, \dots, +1)$.

σ^ν é o passeio homogêneo com configuração inicial $\sigma^\nu(0) = \nu, \nu \in H_N$.

ξ^- é o passeio homogêneo com configuração inicial $\xi^-(0) = (-1, \dots, -1)$.

ξ^+ é o passeio homogêneo com configuração inicial $\xi^+(0) = (+1, \dots, +1)$.

ξ^ν é o passeio homogêneo com configuração inicial $\xi^\nu(0) = \nu; \nu \in H_N$.

$t_N^- := \inf\{t > 0 : \sigma^+(t) = \sigma^-(t)\}$: Tempo de parada/encontro.

$t_N^{\nu, \zeta} := \inf\{t > 0 : \sigma^\nu(t) = \sigma^\zeta(t)\}$: Tempo de parada/encontro.

$D_N(t) := \left| \frac{K^+(t) - P^-(t)}{2N} \right|$ tal que K, P é um passeio preguiçoso ou não preguiçoso:

É a distância no tempo t .

$D_N^{\nu, \zeta}(t) := \left| \frac{K^\nu(t) - P^\zeta(t)}{2N} \right|$ tal que K, P é um passeio preguiçoso ou não preguiçoso:

É a distância no tempo t .

$V[0, N^\gamma] := \{\sigma^+(0), \dots, \sigma^+(N^\gamma)\}$.

O Teorema 2.1 nos dá uma estimativa do crescimento do tempo que leva para dois pontos do hipercubo se encontrarem quando $N \rightarrow \infty$.

Teorema 2.1. *Seja $t_N^- = \inf(t > 0 : \sigma^+(t) = \sigma^-(t))$. Então,*

$$\lim_{N \rightarrow \infty} \mathbb{P} \left(\left| \frac{t_N^-}{N \log N} - 1 \right| > \varepsilon \right) = 0, \forall \varepsilon > 0.$$

Demonstração do Teorema 2.1. Para provar o teorema é suficiente mostrar que

$$\lim_{N \rightarrow \infty} \mathbb{P} \left(\frac{t_N^-}{N \log N} \right) = 1.$$

Seja $D_N(t) = \frac{1}{2N} \sum_{i=1}^N |\sigma_i^+(t) - \sigma_i^-(t)|$ a distância no instante n entre σ^+ e σ^- .

Pela evolução de $\sigma(t)$ temos que $D_N(t)$ é uma cadeia de Markov em $\{0, \frac{1}{N}, \dots, \frac{N-1}{N}, 1\}$ sendo a probabilidade de transição dada por:

$$\mathbb{P}_{xy} = \begin{cases} 1 - x & , \text{ se } y = x, \\ x & , \text{ se } y = x - \frac{1}{N}, \\ 0 & , \text{ c.c.} \end{cases}$$

Definimos $t_N^- = \sum_{k=1}^N \lambda_k$, onde $\lambda_1 = 1$ e λ_k são variáveis aleatórias de geométricas de parâmetros $p_k = 1 - \frac{k-1}{N}$. λ_k são o menor tempo que o processo $D_N(t)$ demora para sair de $1 - \frac{k-1}{N}$ para $1 - \frac{k}{N}$.

Vamos ver a esperança:

$$\begin{aligned} \mathbb{E}(\lambda_k) &= \sum_n^{\infty} \mathbb{P}(\lambda_k = n) \cdot n, \\ &= 1 \cdot p_k + 2 \cdot p_k(1 - p_k) + 3 \cdot p_k(1 - p_k)^2 + \dots \end{aligned}$$

Como $\mathbb{E}(\lambda_k) \cdot (1 - p_k) = 1 \cdot p_k(1 - p_k) + 2 \cdot p_k(1 - p_k)^2 + 3 \cdot p_k(1 - p_k)^3 + \dots$

$$\begin{aligned} \mathbb{E}(\lambda_k) - (1 - p_k) \cdot \mathbb{E}(\lambda_k) &= p_k + p_k \cdot (1 - p_k) + p_k \cdot (1 - p_k)^2 + \dots, \\ p_k \mathbb{E}(\lambda_k) &= p_k(1 + (1 - p_k) + (1 - p_k)^2 + \dots), \\ \mathbb{E}(\lambda_k) &= (1 + (1 - p_k) + (1 - p_k)^2 + \dots), \\ &= \frac{1}{1 - (1 - p_k)} = \frac{1}{p_k} = \frac{N}{N + 1 - k}. \end{aligned}$$

Agora vamos observar a variância:

$$\text{Var}(\lambda_k) = \mathbb{E}(\lambda_k - \mathbb{E}(\lambda_k))^2 = \mathbb{E}(\lambda_k^2) - \mathbb{E}(\lambda_k)^2.$$

Vamos obter $\mathbb{E}(\lambda^2)$:

$$\mathbb{E}(\lambda_k^2) = \sum_x^{\infty} x^2 \cdot \mathbb{P}(\lambda_k = x) = \sum_x^{\infty} x^2 \cdot (1 - p_k)p_k^{x-1},$$

$$= \sum_x^\infty x^2 q^{x-1} p_k = p_k \sum_x^\infty x \frac{d}{dq_k} q_k^x.$$

Sendo $q_k = (1 - p_k)$.

$$\begin{aligned} \mathbb{E}(\lambda_k^2) &= p_k \frac{d}{dq_k} \cdot q \sum_x^\infty x \cdot q_k^{x-1} = p_k \frac{d}{dq_k} \cdot q \sum_x^\infty \frac{d}{dq_k} q_k^x, \\ &= p_k \frac{d}{dq_k} \cdot q \cdot \frac{d}{dq_k} \sum_x^\infty q_k^x = p_k \frac{d}{dq_k} \cdot q \cdot \frac{d}{dq_k} \cdot \left(\frac{q_k}{1 - q_k} \right), \\ &= p_k \left(\frac{1 + q_k}{(1 - q_k)^2} \right) = \frac{2 - p_k}{p_k^2}. \end{aligned}$$

Assim, $\text{Var}(\lambda_k) = \frac{2-p_k}{p_k^2} - \frac{1}{p_k} = \frac{1-p_k}{p_k^2}$. Substituindo $p_k = 1 - \frac{k-1}{N}$, temos $\text{Var} = \frac{N(k-1)}{(N+1-k)}$.

Logo,

$$\begin{aligned} \mathbb{E}(t_N^-) &= \mathbb{E} \left(\sum_{k=0}^N \lambda_k \right) = \sum_{k=0}^N \frac{N}{N+1-k}, \\ &= N \sum_{k=0}^N \frac{1}{N+1-k} = N \sum_{k=1}^N \frac{1}{k}. \end{aligned}$$

Como $\int_1^N \frac{1}{x} dx = \log N$, então $N \log(N-1) \leq \mathbb{E}(\lambda_k) = N \sum_{k=1}^N \frac{1}{k} \leq N \log(N)$.

Quando $n \rightarrow \infty$, $\mathbb{E}(t_N^-) \sim N \log(N)$. Logo, pela desigualdade de Tchebyshev:

$$\begin{aligned} \mathbb{P}(t_N^- - \mathbb{E}(t_N^-) | \varepsilon \cdot \mathbb{E}(t_N^-)) &\leq \frac{\text{Var}(t_N^-)}{\varepsilon^2 \cdot \mathbb{E}(t_N^-)} = \frac{\sum_{k=1}^N \frac{N(k-1)}{(N-K+1)^2}}{\varepsilon^2 \left(\sum_{k=1}^N \frac{N}{N-K+1} \right)^2}, \\ &= \frac{N}{\varepsilon^2 \cdot N^2} \cdot \frac{\sum_{k=1}^N \frac{(k-1)}{(N-k+1)^2}}{\left(\sum_{k=1}^N \frac{1}{N-k+1} \right)^2}. \end{aligned} \quad (2.1)$$

Sendo $N-1$ o maior numero dos termos da soma $\sum_{k=1}^N (k-1)$, então (2.1) é menor ou igual a

$$\frac{N(N-1)}{\varepsilon^2 \cdot N^2} \cdot \frac{\sum_{k=1}^{N-1} \frac{1}{k^2}}{\left(\sum_{k=1}^N \frac{1}{N-k+1} \right)^2} \leq \frac{N(N-1)}{\varepsilon^2 \cdot N^2} \cdot \frac{1 + \sum_{k=2}^{N-1} \frac{1}{k^2 - 1}}{(\log N)^2},$$

$$\leq \frac{N(N-1)}{\varepsilon^2 \cdot N^2} \cdot \frac{1 + \frac{3}{4} - \frac{2N+1}{2N(N+1)}}{(\log N)^2}.$$

Quando $N \rightarrow \infty$,

$$\lim_{N \rightarrow \infty} \frac{N(N-1)}{\varepsilon^2 \cdot N^2} \cdot \frac{1 + \frac{3}{4} - \frac{2N+1}{2N(N+1)}}{(\log N)^2} = 0.$$

Portanto, $\lim_{N \rightarrow \infty} \mathbb{P} \left(\left| \frac{t_N^-}{\mathbb{E}(t_N^-)} - 1 \right| > \varepsilon \right) = 0$. □

Corolário 2.1. *Sejam σ^ν e σ^ζ passeios homogêneos em H_N construídos simultaneamente, com configurações iniciais ν, ζ . Suponha para $0 \leq f \leq 1$, que $D_N(0) = \frac{[N \cdot f]}{N}$.*

Então, $\lim_{N \rightarrow \infty} \mathbb{P}(\sigma^\nu(t(N)) \neq \sigma^\zeta(t(N))) = 0$, para qualquer $t(N)$ com $\lim_{N \rightarrow \infty} \frac{t(N)}{N \log N} = \infty$.

Demonstração Corolário 2.1. Primeiros notamos que $t_N^- = \inf(t > 0 : \{I(1), \dots, I(t)\} = \{1, \dots, N\})$. Assim,

$$\mathbb{P}(\sigma^\nu(t(N)) \neq \sigma^\zeta(t(N))) \leq \mathbb{P}(t_N^- > t(N)) \leq \frac{N(\log N + 1)}{t(N)}.$$

Portanto, por hipótese temos que

$$\lim_{N \rightarrow \infty} \mathbb{P}(\sigma^\nu(t(N)) \neq \sigma^\zeta(t(N))) = 0.$$

□

Corolário 2.2. *Seja $t(N)$ com $\lim_{N \rightarrow \infty} \frac{t(N)}{N \log N} = \infty$. Então,*

$$\lim_{N \rightarrow \infty} \left| \mathbb{P}(\sigma^+(t(N)) = \zeta) - \frac{1}{2^N} \right| = 0,$$

para todo $\zeta \in H_N$.

Demonstração do corolário 2.2. Vamos primeiro mostrar que μ é uma medida invariantes com respeito à evolução do passeio homogêneo.

$$\begin{aligned} \mathbb{P}(x_1 = \zeta) &= \sum_{\nu \in H_N} \mathbb{P}(x_1 = \zeta \mid x_0 = \nu) \cdot \frac{1}{2^N}, \\ &= \mathbb{P}(x_1 = \zeta \mid x_0 = \zeta) \cdot \frac{1}{2^N} + \sum_{i=1}^N \mathbb{P}(x_1 = \zeta \mid x_0 = \zeta^i) \cdot \frac{1}{2^N}, \\ &= \frac{1}{2} \cdot \frac{1}{2^N} + \frac{1}{2} \cdot \frac{1}{N} \cdot \frac{1}{2^N} \cdot N = \frac{1}{2^{N+1}} + \frac{1}{2^{N+1}} = \frac{1}{2^N} = \mathbb{P}(x_1 = \nu). \end{aligned}$$

Assim,

$$\begin{aligned}
\left| \mathbb{P}(\sigma^+(t(N)) = \zeta) - \frac{1}{2^N} \right| &= \left| \mathbb{P}(\sigma^+(t(N)) = \zeta) - \sum_{\nu \in H_N} \mu(\nu) \mathbb{P}((\sigma^\nu = \zeta)) \right|, \\
&\leq \sum_{\nu \in H_N} \mu(\nu) \left| \mathbb{P}(\sigma^+(t(N)) = \zeta) - \mathbb{P}(\sigma^\nu(t(N)) = \zeta) \right|, \\
&\leq \sum_{\nu \in H_N} \sup(\mathbb{P}(\sigma^+(t(N)) \neq \sigma^\nu(t(N)))) = 0.
\end{aligned}$$

A última igualdade é análoga ao corolário anterior. $\square$

Obs: Para um movimento não preguiçoso, $\xi(t)$, talvez não seja possível ocorrer um acoplamento. Se duas configurações iniciais, ν e ζ , diferem em um número ímpar de coordenadas e tem esse tipo de movimentação, nunca poderá haver um acoplamento, pois a distância mínima é, $D_N(t) \geq \frac{1}{N}$.

Demonstração. Seja $\nu, \phi \in H_N$ tal que $D_N^{\nu, \phi}(0) = n$ sendo n um número ímpar. Vamos observar 3 situações possíveis no passeio:

- 1) Se $(\nu^i) = (\phi^i)$, então $(n^i)_i = (\phi^i)_i$;
- 2) Se $(\nu^i) \neq (\phi^i)$, então $(n^i)_i \neq (\phi^i)_i$;
- 3) Se $(\nu^i) = (\phi^i)$, então $(n^i)_i \neq (\phi^i)_j$ sendo $i \neq j$.

Se ocorrer alguns desses casos, a distância das nossas cadeias, ou se mantém a mesma ou afastam-se, mas nunca se aproximam. Logo, supondo que por ventura só alteramos as entradas que são distintas ao longo do tempo. Como a cada passo, $I_\nu(1) = i$ e $I_\phi(1) = j$ tal que $i \neq j$, então $D_N^{\nu, \phi}(1) = n - 2$ já que estamos considerando sempre o melhor dos casos, que seria mudar duas entradas diferentes. Repetindo isso várias vezes, temos que existe um t' tal que $D_N^{\nu, \phi}(t') = 1$, pois n é ímpar e a cada tempo diminuimos duas posições. Assim, caímos no caso 3), ou seja, $D_N^{\nu, \phi}(t) \leq \frac{1}{N}$. $\square$

O Teorema 2.2 nos diz que é certo que $\xi(t)$ retorna a uma posição visitada quando $N \rightarrow \infty$, além de nos mostrar que essa posição de retorno é do tipo $\xi(i)$ e $\xi(j) \forall i, j \leq k + 1$, e $\xi(k + 2) = \xi(k)$ para algum k .

Teorema 2.2. *Seja $S_N = \inf(k > 0 : \xi(k) \in \{\xi(0), \xi(1), \dots, \xi(k - 1)\})$ e $\Gamma_1 = \inf(k > 0 : I(k) = I(k - 1))$. Então, $\lim_{N \rightarrow \infty} \mathbb{P}[S_N = \Gamma_1] = 1$.*

Para a demonstração desse teorema vamos adotar algumas definição e notações:

- 1) Seja I uma variável que escolhe uma coordenada i de um $\nu \in H_N$. Vamos denotar I avaliado no tempo k como I_k .
- 2) $J_1 = \{(I_1, I_2) \in \{1, 2, \dots, N\}^2 : I_1 = I_2\}$.
- 3) $J_l = \{(I_1, I_2, \dots, I_{2l}) \in \{1, 2, \dots, N\}^{2l} : \sum_{k=1}^{2l} 1_{\{i=I_k\}} \in \{0, 2, 4, \dots, 2l\} \forall i \in \{1, 2, \dots, N\} \text{ e } (I_1, I_2, \dots, I_{2k}) \notin J_k \forall k \in \{1, 2, \dots, l-1\}\}$.
- 4) Definimos um grupo de $i \in \{1, 2, \dots, N\}$ do vetor $(I_1, I_2, \dots, I_{2l}) \in J_l$ como $\{k \in \{1, 2, \dots, 2l-1, 2l\} : i = I(k)\}$.

Uma forma de pensar nos vetores desses J 's é ver eles como caminho na forma de laço.

Proposição 2.1. Para $l \geq 3$

$$\mathbb{P}(I_1, \dots, I_{2l}) \in J_l \leq \frac{8}{N^3}.$$

Demonstração da Proposição. 2.1 Sabemos que $\mathbb{P}(I_1, \dots, I_{2l}) \in J_l = \frac{|J_l|}{N^{2l}}$. Fazendo uma estimativa superior temos que $|J_l| \leq 2N^{2l-2}$, pois sendo $(I_1, \dots, I_{2l}) \in J_l$, então $(I_1, \dots, I_{2l-2}) \notin J_{l-1}$, evitando a recursividade, podemos supor que $\exists i' \in \{1, \dots, N\}$ tal que $\sum_{k=1}^{2l-2} 1_{\{i'=I_k\}}$ é ímpar, como o tamanho do vetor é par, então deve $\exists i'' \neq i'$ tal que $\sum_{k=1}^{2l-2} 1_{\{i''=I_k\}}$ é ímpar. Logo, como $(I_1, I_2, \dots, I_{2l-1}, I_{2l}) \in J_l$, então $\sum_{k=1}^{2l} 1_{\{i'=I_k\}}$ e $\sum_{k=1}^{2l} 1_{\{i''=I_k\}}$ são somas pares, ou seja, os dois últimos índices são determinados pelos i' e i'' . Como i' e i'' são diferentes, então podemos permutá-los, assim $|J_l| \leq 2N^{2l-2}$. Podemos dividir J_l em dois conjuntos disjuntos, J_l'' e J_l' , onde J_l'' é o conjunto onde nas três últimas entradas existe duas iguais, e J_l' é o conjunto onde as três últimas entradas são distintas. Vamos achar uma estimativa superior para esse conjuntos. Em J_l' como a entrada $2l-2$ é distinta das duas últimas e sabemos que temos dois blocos ímpares distintos que determinam as duas últimas entradas, então o bloco de I_{2l-2} no subvetor $(I_1, I_2, \dots, I_{2l-3})$ é ímpar, pois se fosse o contrário, a soma $\sum_{k=1}^{2l} 1_{\{I_{2l-2}=I_k\}}$ seria ímpar. Logo, a entrada $2l-2$ é determinado por um terceiro bloco ímpar. Logo, $|J_l'| \leq 3!N^{2l-3}$. No conjunto J_l'' perceba que como $I_{2l-1} \neq I_{2l}$, então existem somente dois casos $I_{2l-2} = I_{2l}$ e $I_{2l-1} = I_{2l-2}$. Sem perda de generalidade, vamos supor que é verdade $I_{2l-1} \neq I_{2l}$. Como ambas as duas coordenadas estão determinadas pelo mesmo bloco, então podemos lidar com esse vetor de $2l$ entradas como se fosse de $2l-2$ entradas. Assim, $|J_l''| \leq N \cdot |J_{l-1}''|$, pois as coordenada

repetida pode ter combinação de N valores. Portanto,

$$\frac{|J_l|}{N^{2l}} = \frac{|J'_l|}{N^{2l}} + \frac{|J''_l|}{N^{2l}} \leq \frac{3!N^{2l-3}}{N^{2l}} + \frac{N \cdot 2N^{2l-4}}{N^{2l}} = \frac{8}{N^3}.$$

□

Capítulo 3

Abordagem Potencial para Metaestabilidade

Vamos denotar $E_N, N \geq 1$, o conjunto de estados de uma malha quadrada de largura N e dimensão d , como representado abaixo. Os estados (pontos ou configurações) de E_N é representado por η, ξ, ζ .




Figura 3.1: Malha $\Lambda_N = \{0, \dots, N\}^d$ com um elemento de E_N destacado por azul.

Se considerarmos uma evolução dos estados podemos indexar E_N para cada tempo, $E_{t,N}$. Para isso, consideremos que para $E_{t,N}$, temos um sequencia de malhas Λ_N onde para cada par de malhas vizinhas temos somente um ponto em comum, como a figura a abaixo.




Figura 3.2: Um caminhar aleatório com dois estados

Assim podemos definir E_N como a união dos $E_{t,N}$, ou seja, podemos pensar E_N como os estados de uma partícula de $0 \leq t \leq p$ sendo p um inteiro. Vamos denotar $\eta_N(t)$ uma cadeia de Markov de tempo contínuo em E_N tal que o pulo de $\eta \in E_{t,N}$ para seus vértices vizinhos é uniforme, e para mudar seu estado espera um tempo exponencial. Perceba que essa cadeia de Markov é irreduzível.

Dizemos que o grau de $\eta \in E_N$, $\deg(\eta)$, é quantidade de vizinhos. Assim conseguimos definir uma medida de probabilidade

$$\pi_N(\eta) = \frac{\deg(\eta)}{Z_N}$$

onde $Z_N = \sum_{\xi \in E_N} \deg(\xi)$. Então, como sabemos que π_N satisfaz a *Equação de balanço*, então a distribuição é estacionária e única. Vamos estudar o exemplo *Coarse-grained-model*. Vamos denotar $\Gamma_N : E_N \rightarrow \{0, 1, 2, 3\}$ a projeção de uma partícula no seu tempo,

$$\Gamma_N(\eta) = \sum_{k=0}^3 k \chi_{E_{k,N}}(\eta).$$

Perceba que não tem problema nas intersecções dos quadrados, pois cada quadrado irá ter $(N^d - 1)$ vértices. A função da evolução assintótica do *Coarse-grained-model*

$$\mathbf{Y}_N(t) = \Gamma_N(\eta_N(t))$$

é um passeio aleatório entre cubos discretos. Vamos denotar $z_N(t)$ o andar aleatório simétrico, de tempo contínuo em Λ^N , ou seja, o processo η_N restrito a Λ_N , ademais

seja $\pi_N(\Lambda_N)$ a medida estacionária em Λ_N . Pela proposição??, temos que a ordem com que $z_N(t)$ converge para uma transição estacionária é de N^2 , além disso o tempo estimado de um ponto x para outro que dista N é da ordem $\alpha_N = N^2 \log N$ em dimensão $d = 2$ e $\alpha_N = N^d$ em dimensão $d \geq 3$.

Assumindo que iniciamos no centro de $\mathbb{Z}_N^d$. Definamos também B como o conjunto dos pontos de intersecção, $E_{j,N} \cap E_{i,N}$ para todo $j \neq i$. Logo, seja

$$H_B^N = \inf\{t \geq 0 : \eta_N(t) \in B\}.$$

Como a ordem de H_B^N é maior que a ordem de convergência da cadeia para sua estacionária, então dizemos que ela termaliza ou equilibra antes de chegar nas quinas compartilhadas. Assim podemos intuir que quanto mais perto de B mais nossa "partícula" esquece do caminho que veio, como consequência a probabilidade da partícula mudar de estado se a próxima de $\frac{1}{2}$. Quando a partícula termaliza, ela passeia em $E_{j,N}$ em um tempo de ordem α_N até chegar em ponto de intersecção, que denominamos de ξ . Para evitar essa pergunta, podemos definir uma sequência $(l_N : N \geq 1)$ de números reais tais que $l_N \rightarrow \infty$ e $\frac{l_N}{N} \rightarrow 0$. Assim criamos V_N , o conjunto dos pontos que distam até l_N de ξ . Após alcançar ξ , nosso caminho aleatório faz um pequeno percurso em V_N . Como escolhemos uma boa vizinhança, o que poderia acontecer, de a partícula voltar para ξ antes de sair de V_N , certamente não acontecerá, pois a ordem da partícula escapar de V_N é menor que a ordem do tempo de encontro. Para $d = 2$,

$$\frac{\ell_N^2}{\alpha_N} = \frac{\ell_N^2}{N^2 \log N} = \left(\frac{t}{N}\right)^2 \cdot \frac{1}{\log N} \rightarrow 0 \cdot 0 = 0.$$

Para $d \geq 3$,

$$\frac{\ell_N^2}{\alpha_N} = \frac{\ell_N^2}{N^2} = \left(\frac{t}{N}\right)^2 \rightarrow 0.$$

Nesse vai e volta ao ξ dentro do V_N que pode está ocorrendo em $E_{i,N}$ ou $E_{i\pm 1,N}$, ao alcançar um tempo de ordem l^2 , a partícula consegue escapar do V_N . Perceba que esse tempo é irrisório comparado ao tempo de encontro nas quinas, α_N . Desde que esse tempo seja muito maior do que o tempo de equilíbrio, temos a repetição do processo novamente.

3.1 Apêndice A

Como base para entendermos o escopo deste trabalho, foi criado algumas simulações usando a linguagem Python, fazendo uso das bibliotecas *matplotlib*,

Pandas e Numpy.




Figura 3.3: Acoplamento de dois caminhar aleatório com N fixo

Referências Bibliográficas

- [Kipnis-Landim] C. Kipnis and C. Landim, *Scaling Limits of Interacting Particle Systems* , Springer-Verlag Berlin Heidelberg, (1999).
- [Tsallis] Tsallis, Constantino , *Introduction to Nonextensive Statistical Mechanics*, New York, (2009).
- [Shannon] Shannon, C. E. , *A Mathematical Theory of Communication* , The Bell System Technical Journal, (1948).
- [Khinchin] Khinchin, A. I. , *Mathematical Foundations of Information Theory* , New York, (1957).
- [Durrett] Durrett, Richard. , *Probability, Theory and Examples* , Brooks/Cole, (2005).
- [Boucheron-Lugosi-Massart] S. Boucheron, G. Lugosi and P. Massart, *Concentration Inequalities* , Oxford, (2013).
- [Norris] Norris, J.R. , *Markov Chains* , Cambridge, (1997).

Universidade Federal da Bahia-UFBA
Instituto de Matemática / Colegiado da Pós-Graduação em Matemática

Av. Adhemar de Barros, s/n, Campus de Ondina, Salvador-BA
CEP: 40170 -110
www.pgmat.ufba.br