



UNIVERSIDADE FEDERAL DA BAHIA - UFBA
INSTITUTO DE MATEMÁTICA - IM
TRABALHO DE CONCLUSÃO DE CURSO - TCC
MONOGRAFIA



METAESTABILIDADE

JOÃO DELGADO

Salvador - Bahia
27 de março de 2026

METAESTABILIDADE

JOÃO VICTOR FONSECA DELGADO DA SILVA

Orientador: Prof. Dr. Tertuliano Franco
Santos Franco.

Salvador - Bahia
27 de março de 2026

Agradecimentos

“Mede o que é mensurável e torna mensurável o que não o é”.

Galileu Galilei (1564-1642)

Resumo

O objetivo desta dissertação é estudar e apresentar alguns resultados sobre
.....

Palavras-chave: sistemas de partículas, cadeias de Markov.

Abstract

The objective of this dissertation is .

Keywords: random graphs, phase transition.

Conteúdo

Introdução	1
1 Noções básicas de medida e probabilidade	2
1.1 Cadeia de Markov	6
1.2 Função de representação aleatória	7
1.3 Passeio aleatório em grafos	9
1.4 Distribuição estacionária	10
2 Metaestabilidade para o passeio aleatório no hipercubo	11
2.1 Tipos de passeios aleatórios homogêneos:	11
2.1.1 Passeio homogêneo preguiçoso $\sigma(t)$	11
2.1.2 Passeio homogêneo não preguiçoso $\xi(t)$	12
3 Abordagem Potencial para Metaestabilidade	19
3.1 Apêndice A	21
Referências Bibliográficas	23
Índice Remissivo	24

Lista de Figuras

3.1	Malha $\Lambda_N = \{0, \dots, N\}^d$ com um elemento de E_N destacado por azul.	19
3.2	Um caminhar aleatório com dois estados	20
3.3	Acoplamento de dois caminhar aleatório com N fixo	22

Introdução

A metaestabilidade é um fenômeno que surge em diversos contextos, especialmente no estudo de sistemas dinâmicos e probabilísticos. Sua investigação ganhou notoriedade a partir da necessidade de compreender comportamentos aparentemente estáveis em sistemas que, a longo prazo, sofrem transições abruptas entre estados. Historicamente, esse tema está associado ao desenvolvimento da teoria das probabilidades, da mecânica estatística e das cadeias de Markov, áreas impulsionadas por problemas oriundos tanto da física quanto da matemática pura. Contribuições fundamentais de diversos pesquisadores ao longo do século XX permitiram a consolidação dessas ideias, estabelecendo as bases teóricas para o estudo rigoroso da metaestabilidade.

De forma geral, a metaestabilidade descreve situações em que um sistema permanece por longos períodos em estados que não são verdadeiramente estáveis, mas que apresentam uma estabilidade aparente antes de ocorrer uma transição para um estado mais estável. Esse comportamento é particularmente relevante em modelos probabilísticos, nos quais a análise do tempo de permanência e das transições entre estados desempenha um papel central. Assim, o estudo da metaestabilidade torna-se essencial para a compreensão de fenômenos complexos, com aplicações que vão desde processos físicos até algoritmos estocásticos.

Neste trabalho, serão apresentados inicialmente conceitos fundamentais necessários para o desenvolvimento do tema, com destaque para noções básicas de probabilidade e cadeias de Markov. Em seguida, será abordado um modelo específico de sistema em tempo discreto definido em um reticulado (lattice), com base em uma aula ministrada pelo professor Peixoto em um curso de verão do IMPA, que servirá como motivação e exemplo concreto do fenômeno estudado. Por fim, será explorada uma abordagem baseada em potenciais, fundamentada no artigo de Claudio Landim, permitindo uma análise mais aprofundada das propriedades metaestáveis e de suas implicações teóricas.

Capítulo 1

Noções básicas de medida e probabilidade

Nesse capítulo vamos falar das noções iniciais de probabilidade para que possamos compreender os processos de metaestabilidade. Inicialmente falaremos da construção da σ -álgebra e as consequências de imbuir esse objeto com uma medida, assim seguindo para a construção da medida de probabilidade. Em sequência, falamos um sobre as propriedades das cadeias de Markov, que são um dos objetos mais importantes quando falamos de metaestabilidade.

Definição 1.1. *Uma álgebra de um conjunto Ω é uma classe $\mathcal{F}$ de subconjuntos de Ω tal que:*

- i. $\Omega \in \mathcal{F}$,*
- ii. $A \in \mathcal{F}$ implica que $A^c \in \mathcal{F}$,*
- iii. $A, B \in \mathcal{F}$ implica que $A \cup B \in \mathcal{F}$.*

Uma álgebra é uma classe que se pode realizar operações elementares de conjuntos, o que é característica muito boa, pois como funções trabalham com conjunto e, sem esses objetos, ficamos muito restritos ou até de mãos atadas ao desenvolver uma teoria. Contudo, a álgebra ainda não é uma estrutura adequada para trabalhar com probabilidade, pois, apesar das uniões de dois elementos da álgebra estarem na álgebra, a união infinitesimal desses elementos pode não estar no conjunto. Logo, precisamos de uma estrutura que seja fechada para uniões enumeráveis.

Definição 1.2. *Uma σ -álgebra é uma álgebra fechada por uniões enumeráveis, ou seja,*

- iv. $A_j \in \mathcal{F}$ tal que $j = 1, 2, \dots$ implica que $\bigcup_{j=1}^{\infty} A_j \in \mathcal{F}$.*

Exemplo 1.1. Um exemplo básico de uma σ -álgebra é o que corresponde ao lançamento de um dado de 6 lados honesto. O nosso conjunto de estudo seria os lados do dado, $D = \{1, 2, 3, 4, 5, 6\}$ e nossa σ -álgebra é $\mathcal{S} = \mathcal{P}(D)$, as partes de D .

Definição 1.3 (σ -álgebra gerada por uma classe de subconjuntos). Seja $\mathcal{E}$ uma classe de subconjuntos de Ω . Então definamos $\sigma(\mathcal{E})$ como a única σ -álgebra gerada por $\mathcal{E}$ que satisfaz:

- i. $\sigma(\mathcal{E})$ é σ -álgebra,
- ii. $\mathcal{E} \subseteq \sigma(\mathcal{E})$,
- iii. Se $\mathcal{S}$ é σ -álgebra $\mathcal{E} \subseteq \mathcal{S}$, então implica que $\sigma(\mathcal{E}) \subseteq \mathcal{S}$.

Exemplo 1.2. Ainda pensando no dado, tomemos uma classe de conjuntos $\mathcal{E} = \{\{1, 2\}\}$. Podemos criar uma σ -álgebra, $\sigma(\mathcal{E})$, adicionando $D, \{1, 2\}, \emptyset, \{3, 4, 5, 6\}$ em $\sigma(\mathcal{E})$, logo temos $\sigma(\mathcal{E}) = \{D, \emptyset, \{1, 2\}, \{3, 4, 5, 6\}\}$. Perceba que as uniões dois-a-dois são fechadas, então $\sigma(\mathcal{E})$ é σ -álgebra.

Criado o nosso espaço onde vamos estudar (espaços mensuráveis), podemos começar a elaborar a ideia de probabilidade.

Definição 1.4. Uma medida em um espaço mensurável, $(\Omega, \mathcal{S})$, é uma função $\mu : \mathcal{S} \rightarrow [0, +\infty]$ que satisfaz:

- i. $\mu(\emptyset) = 0$,
- ii. $\mu\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mu(A_i)$ para todo $A_i \in \mathcal{S}$ dois a dois disjuntos.

A tripla $(\Omega, \mathcal{S}, \mu)$ denomina-se espaço de medida.

Observe que isso inclui somas finitas, pois podemos considerar os A_n tal qual para todo $n > n_0$ é igual a $\emptyset$. Um exemplo importante de medida é a delta de Dirac:

Exemplo 1.3. Seja Ω um conjunto e consideremos $\mathcal{P}(\Omega)$, as partes de Ω , então dado um $p \in \Omega$, seja a função $\delta_p : \mathcal{P}(\Omega) \rightarrow [0, +\infty]$:

$$\delta_p(A) = \begin{cases} 1, & \text{se } p \in A; \\ 0, & \text{c.c.} \end{cases}$$

Vamos agora ver algumas propriedades das medidas que não são nenhuma surpresa, mas que precisamos formular.

Teorema 1.1. Seja $(\Omega, \mathcal{S}, \mu)$ um espaço de medida e $A, B, A_1, A_2, \dots \in \mathcal{S}$.

1. $\mu(A^c) = \mu(\Omega) - \mu(A)$,
2. Se $A \subseteq B$, então vale que $\mu(A) \leq \mu(B)$ e $\mu(B \setminus A) = \mu(B) - \mu(A)$,
3. $\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B)$,
4. $\mu\left(\bigcup_{n=1}^{\infty} (A_n)\right) \leq \sum_{n=1}^{\infty} \mu(A_n)$,
5. Se $\mu(A_n) < \infty$, $A_n \uparrow A$ ou $A_n \downarrow A$, então $\mu(A_n) \rightarrow \mu(A)$.

Demonstração. 1. Como $\Omega = A \cup A^c$, temos que $\mu(\Omega) = \mu(A \cup A^c) = \mu(A) + \mu(A^c)$.

2. Como $A \subseteq B$, então $B = A \cup B \setminus A \Rightarrow \mu(B) = \mu(A \cup B \setminus A) = \mu(A) + \mu(B \setminus A) \Rightarrow \mu(B \setminus A) = \mu(B) - \mu(A)$.

3. Usando o item (ii) temos que $\mu(A \cup B) = \mu(A) + \mu(B \setminus A)$. Como $\mu(B) = \mu(B \setminus A) + \mu(A \cap B)$, então $\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B)$.

4. A partir de uma sequência de A_n podemos criar uma sequência disjunta. Seja $B_1 = A_1$, $B_2 = A_2 \setminus A_1$, $B_3 = A_3 \setminus (A_2 \cup A_1)$, etc. Ou seja, $B_n = A_n \setminus (\bigcup_{j=1}^{n-1} A_j)$, perceba que B_n é uma sequência de conjuntos disjunta. Assim $\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \mu\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} \mu(B_n) \leq \sum_{n=1}^{\infty} \mu(A_n)$.

5. Suponhamos que $A_n \uparrow A$, então $A_n \subset A_{n+1}$. Como é uma sequência de conjuntos arbitrário, a fim de obter melhor controle, podemos criar uma sequência B_n de conjuntos disjunta tal que $\bigcup_n^{\infty} B_n = \bigcup_n^{\infty} A_n$, definindo $B_n = A_n \setminus A_{n-1}$ sendo $A_0 = \emptyset$.
 Fixe um $k \in \mathbb{N}$ e $i \geq 1$. Daí, $\bigcup_i^k B_i = \bigcup_i^k (A_i \setminus A_{i-1})$ nos leva a

$$\begin{aligned}
 \mu\left(\bigcup_i^k B_i\right) &= \mu\left(\bigcup_i^k (A_i \setminus A_{i-1})\right), \\
 &= \sum_i^k \mu(A_i \setminus A_{i-1}), \\
 &= \sum_i^k (\mu(A_i) - \mu(A_{i-1})).
 \end{aligned}$$

Como o lado direito da equação é uma soma telescópica, temos que $\mu(\bigcup_i^k B_i) = \mu(A_k) - \mu(A_0)$. Logo,

$$\begin{aligned} \lim_{k \rightarrow \infty} \mu \left(\bigcup_i^k B_i \right) &= \lim_{k \rightarrow \infty} \mu(A_k), \\ \Rightarrow \mu \left(\bigcup_i^\infty B_i \right) &= \mu \left(\bigcup_i^\infty A_i \right) = \mu(A). \end{aligned}$$

Para provar $A_n \downarrow A$, podemos utilizar o que acabamos de provar. Tome a sequência $A_n^c \uparrow A^c$ e lembrando que $P(A_n) = 1 - P(A_n^c)$, então se $n \rightarrow \infty$ temos que $\lim_{n \rightarrow \infty} P(A_n) = 1 - P(A^c)$. □

Agora que entendemos um pouco sobre medidas e σ -álgebras, podemos começar a adentrar no assunto de probabilidade. Contudo o que seria uma probabilidade? É intuitivo pensar que probabilidade satisfaça as definições de medida, pois com esse objeto temos o intuito de medir quão provável um evento pode ocorrer.

Definição 1.5. *Seja $(\Omega, \mathcal{S}, \mu)$ um espaço de medida. Se $\mu : \mathcal{S} \rightarrow \mathbb{R}$ é uma função que satisfaz:*

- i. $\mu(\Omega) = 1$,
- ii. $\mu \left(\bigcup_{i=1}^\infty A_i \right) = \sum_{i=1}^\infty \mu(A_i)$ para todo $A_i \in \mathcal{S}$ dois a dois disjuntos.

Então μ é uma medida de probabilidade. A tripla $(\Omega, \mathcal{S}, \mu)$ denomina-se espaço de probabilidade.

Perceba que pela afirmação 1, temos que $\mu(\Omega) = 1 - \mu(\emptyset) = 1$. Logo, essa definição para probabilidade μ , nos diz que também é medida, assim tudo que vimos para medida vale para probabilidade.

Seja $(\Omega, \mathcal{S}, \mu)$ um espaço de probabilidade. Tome dois eventos $A, B \in \mathcal{S}$ tais que $\mu(A) = a$ e $\mu(B) = b$. Qual é a probabilidade do evento acontecer A se sabemos que o evento B acontece?

Definição 1.6. *Seja $(\Omega, \mathcal{S}, \mu)$ um espaço de probabilidade e $A, B \in \mathcal{S}$ tal que $\mu(B) > 0$. Uma probabilidade condicional de A dado B é $\mathbb{P} : \mathcal{S} \rightarrow \mathbb{R}$*

$$\mathbb{P}(A|B) = \frac{\mu(A \cap B)}{\mu(B)}.$$

Quando $\mu(B) = 0$, então definimos $\mathbb{P}(A|B) = \mathbb{P}(A)$.

A probabilidade condicional diferente da noção usual de probabilidade, contextualiza as chances de um evento acontecer. Perceba que quando $\mathbb{P}(B) > 0$, a primeira nada mais é do que relativização da probabilidade do evento A para o evento B . Veja que estamos falando de eventos, elementos da σ -álgebra e não qualquer subconjunto de Ω .

Teorema 1.2 (Regra do produto). *Em $(\Omega, \mathcal{S}, \mu)$. Dados os eventos $A_1, A_2, \dots, A_n \in \mathcal{S}$,*

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1)\mathbb{P}(A_2|A_1)\mathbb{P}(A_3|A_1 \cap A_2) \dots \mathbb{P}\left(A_n \left| \bigcap_{i=1}^{n-1} A_i\right.\right).$$

Definição 1.7 (Eventos independentes). *Seja $A, B \in \mathcal{S}$ são independentes se*

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Logo, se a sequência de eventos A_i são independentes, então $\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n \mathbb{P}(A_i)$, pois $\mathbb{P}(A_j|A_i) = \mathbb{P}(A_j)$.

1.1 Cadeia de Markov

Definição 1.8 (Cadeia de Markov finita). *Seja $(\Omega, \sigma\{\Omega\}, \mathbb{P})$ um espaço de probabilidade e $(X_1, X_2, X_3, \dots)$ uma sequência aleatória de variáveis que satisfaz, juntamente com uma matriz de transição $\mathbb{P}$, a propriedade de Markov, definida da seguinte forma: Se para $\forall x, y \in \Omega$, para todo $t \geq 1$, e para todo evento $H_{t-1} = \bigcap_{s=0}^{t-1} \{X_s = x_s\}$ satisfaz $\mathbb{P}(H_{t-1} \cap \{X_t = x\}) > 0$, nos temos que*

$$\mathbb{P}\left\{X_{t+1} = y | H_{t-1} \cap \{X_t = x\}\right\} = \mathbb{P}\{X_{t+1} = y | \{X_t = x\}\}.$$

Em termos mais amigáveis, a probabilidade de a sequência chegar a um determinado estado depende apenas do estado anterior, podemos pensar nisso como uma sequência que apresenta perda de memória. Como estamos trabalhando com probabilidade, a soma das chances de transição de um estado para todos os outros deve ser igual a 1. Por isso, a nossa matriz de transição precisa ser estocástica.

Definição 1.9 (Matriz estocástica). *Denominamos P de matriz estocástica, se as suas entradas são não-negativas e a soma de elementos de cada coluna da matriz é igual a um, isso é, $\sum_{j \in |\Omega|} P_{ij} = \mathbb{P}(x, \cdot) = 1 \forall x \in \Omega$.*

Em muitos casos gostaríamos de trabalhar com distribuições de pontos diferentes do espaço, $\mathbb{P}(x, \cdot), \mathbb{P}(y, \cdot)$, então para facilitar a compreensão, vamos utilizar a notação $\mathbb{E}_x, \mathbb{P}_x$.

$$\mathbb{E}_x(f(X_1)) = \sum_y f(y) \mathbb{P}_x(X_1 = y) = \sum_y f(y) \mathbb{P}(x, y) = \mathbb{P}f(X).$$

tal que f é uma função. Notação: $\mathbb{P}_x(X_t = y) = (\delta_x \mathbb{P}^t)(y) = \mathbb{P}^t(x, y)$.

1.2 Função de representação aleatória

Definição 1.10 (Função de representação aleatória de uma matriz P em um espaço de estados Ω). *A função f é uma representação aleatória se $f : \Omega \times \Lambda \rightarrow \Lambda$, onde Λ são os valores da variável aleatória Z definida em Ω , satisfaz*

$$\mathbb{P}(f(x, Z(x)) = Y) = \mathbb{P}(x, y).$$

A função de representação é uma ótima ferramenta para substituírmos a matriz de transição quando temos uma quantidade extensa de estados tornando as operações laboriosas. Seja uma sequência de variáveis $(Z_n)_n$ iid's com mesma distribuição de Z e X_0 com distribuição μ , podemos definir uma sequência de variáveis aleatórias $(X_n)_n$ como

$$X_n = f(X_{n-1}, Z_n) \quad n \geq 1,$$

tal que essa sequência é uma cadeia de Markov com uma matriz de transição P com distribuição μ .

Proposição 1.1. *Toda matriz de transição em um espaço de Markov finito tem uma função de representação aleatória.*

Demonstração. Seja P uma matriz de transição de um espaço de Markov com o espaço de estados $\Omega = \{x_1, x_2, \dots, x_n\}$ e seja $\Lambda = [0, 1]$, onde as variáveis aleatórias auxiliares $Z, Z_1, Z_2, \dots$ são iid's nesse intervalo. Definamos $F_{ij} = \sum_{k=1}^j \mathbb{P}(x_i, x(k))$, então podemos definir f como $f(x_i, Z) := x_j$ quando $F_{i,j-1} < Z < F_{i,j}$. Portanto,

$$\mathbb{P}\{f(x_i, Z) = x_j\} = \mathbb{P}\{F_{i,j-1} < Z < F_{i,j}\} = \mathbb{P}(x_i, x_j).$$

□

Veremos em seguidas algumas propriedades dessas cadeias de Markov que nos permite extrair algumas informações.

Definição 1.11 (Irredutível). *Seja P uma cadeia, se para todo $x, y \in \Omega$, existe um inteiro t tal que $\mathbb{P}^t(x, y) > 0$.*

Definição 1.12 (Período de x). *Definamos o conjunto $T(x) = \{t \geq 1 : \mathbb{P}^t(x, x) > 0\}$. O período de x é o maior divisor comum (mdc de $T(x)$).*

Proposição 1.2. *Se P é irredutível, então $\text{mdc}(T(x)) = \text{mdc}(T(y))$ para $x, y \in \Omega$.*

Demonstração. Seja $k \in T(x)$. Sabemos que existe r e l tal que $\mathbb{P}^r(x, y) > 0$ e $\mathbb{P}^l(x, y) > 0$. Seja $m = r + l$, é direto ver que $m \in T(x) \cap T(y)$. Provaremos que $k + m \in T(y)$,

$$\begin{aligned}\mathbb{P}^{k+m}(x, x) &= \mathbb{P}^k(x, x)\mathbb{P}^r(x, y)\mathbb{P}^l(y, x) \\ &= \mathbb{P}^l(y, x)\mathbb{P}^k(x, x)\mathbb{P}^r(x, y) \\ &= \mathbb{P}^{l+k+r}(y, y) = \mathbb{P}^{m+k}(y, y)\end{aligned}$$

Então $k + m \in T(y)$, então $k \in T(y) - m \Rightarrow T(x) \subset T(y) - m$. Portanto, $\frac{\text{mdc}(T(y))}{T(x)}$, consequentemente $\text{mdc}(T(y)) \leq \text{mdc}(T(x))$. Para $\text{mdc}(T(x)) \leq \text{mdc}(T(y))$ é análogo. Portanto, $\text{mdc}(T(y)) = \text{mdc}(T(x))$. $\square$

Definição 1.13 (Aperiódico). *Se em uma cadeia o $\text{mdc}(T(x)) \forall x \in \Omega$ é 1, então denominamos aperiódico. Se a cadeia não é aperiódico, então é periódico.*

Proposição 1.3. *Se P é irredutível, então existe um inteiro r tal que $\mathbb{P}^r(x, y) > 0$ para $\forall x, y \in \Omega$.*

Demonstração. Antes de provar essa proposição, iremos demonstrar um lema que nos garantirá que a partir de um inteiro vai ser possível o retorno de um $x \in \Omega$.

Lema 1.1. *Seja $S \subset \mathbb{Z}^+$ tal qual é fechado por adição e de $\text{mdc}(S) = 1$, então existe $m_s \in \mathbb{Z}^+$ tal que para todos $m \geq m_s$ pode ser escrito como combinação linear de elementos de S .*

Demonstração. Como o $\text{mdc}(S) = 1$, podemos aplicar o Teorema de Bézout. Seja $a, b \in S, \exists x, y \in \mathbb{Z}, ax + by = 1$. O caso de $x, y \geq 0$, então está feito. O caso de $x, y < 0$, não ocorre, pois $a, b \leq 0$. Então só nos resta o caso de $x > 0$ e $y < 0$ ou contrário. Suponhamos que $y > 0$ e $x < 0$, e seja $k \in \mathbb{Z}^+$, logo $\exists r, q \in \mathbb{Z}^+(k = aq + r \wedge a \geq r \geq q)$.

$$\begin{aligned}1 &= xa + yb \\ r &= rxa + ryb, \\ k &= aq + r = rxa + aq + ryb \\ k &= (rx + q)a + ryb.\end{aligned}$$

Como $y > 0$ e $r \leq 0$, então só precisamos verificar $xr + q$. Lembrando que $x < 0$, logo $(-x) > 0$.

$$xr + q > 0 \Leftrightarrow q > (-x)r.$$

Como $a > r$, então $q > (-x)a$. □

Agora, podemos provar a proposição 1.3. Vamos provar que $\forall x \in \Omega$, $T(x)$ é fechado por adição. Seja $a, b \in T(x)$, $\mathbb{P}^{a+b}(x, x) = \mathbb{P}^a(x, x)\mathbb{P}^b(x, x) > 0$, então $a + b \in T(x)$. Logo, pelo lema anterior, sabemos que existe t_x tal que $t \geq t_x$, $\mathbb{P}^{t_x}(x, x) > 0$. Como sistema é irredutível, então existe um inteiro $k = k(x, y)$ tal que $\mathbb{P}^k(x, y) > 0$. Logo, fixado x , seja $t = t_x + r(x, y)$,

$$\mathbb{P}^t(x, y) \geq \mathbb{P}^{t_x}(x, x)\mathbb{P}^{r(x, y)}(x, y) > 0.$$

□

1.3 Passeio aleatório em grafos

Um grafo $G = (V, E)$ consiste em um conjunto de vértice V e um conjunto de aresta E , onde $E \subset \{\{x, y\} : x, y \in V \text{ e } x \neq y\}$ e V é o conjunto de pontos tal que para cada par de ponto ligados por um linha. Denotando $\{x, y\} \in E$ como $x \sim y$, chamamos y de vizinhança de x . E o total de vizinhança de x como o grau de x , ou seja, $|\{x \sim y : y \in V\}| = \deg(x)$.


Como um exemplo inicial, podemos definir um grafo e criar uma função de probabilidade a partir da vizinhança de um ponto, tornando a escolha de um vértice pular para outro, ser uniforme.

$$\mathbb{P}(x, y) = \begin{cases} \frac{1}{\deg(x)}; & \text{se } x \sim y, \\ 0; & \text{c.c.} \end{cases}$$

Exemplo 1.4. Seja G um grafo de 2 vértices. Então temos uma matriz de transição

$$P = \begin{pmatrix} \frac{1}{2} & 1 \\ \frac{1}{2} & 0 \end{pmatrix}.$$

Ou seja,



1.4 Distribuição estacionária

Em caminhadas aleatórias podemos andar tanto e acabar tendendo a algum lugar. Assim, se verificarmos que a distribuição de uma caminhada aleatória está tendendo para algum lugar, então dizemos que ela é estacionária.

Definição 1.14. *Seja P uma matriz de transição em grafo G . Definimos como uma distribuição estacionária, quando uma medida de probabilidade π satisfaz*

$$\pi = \pi P.$$

De forma equivalente podemos reescrever nossa definição como

$$\pi(y) = \sum_{x \in V} \pi(x) P(x, y).$$

Exemplo 1.5. *Utilizando o simples andar aleatório sobre um grafo $G = (V, E)$. Para qualquer $y \in V$*

$$\sum_{x \in V} \deg(x) P(x, y) = \sum_{x \sim y} \frac{\deg(x)}{\deg(x)} = \deg(y)$$

Utilizando como normalizador $\sum_{y \in V} \deg(y) = 2|E|$, podemos dizer que a medida de probabilidade

$$\pi(y) = \frac{\deg(y)}{2|E|} \quad \forall y \in V$$

é uma distribuição estacionária.

Capítulo 2

Metaestabilidade para o passeio aleatório no hipercubo

Chamaremos $H_N = \{-1, +1\}^N$ um conjunto de configurações de N spins (as entradas) com possíveis valores $\{+1, -1\}$. Os elementos do H_N são representados por ν e ζ , ou seja, $\nu = (\nu_1, \dots, \nu_N)$ e $\zeta = (\zeta_1, \dots, \zeta_N)$ onde ζ_i e $\nu_i \in \{+1, -1\}, \forall i \in \{1, \dots, N\}$. Seja $\nu \in H_N$, o valor da troca no spin j de ν é denotado por ν^j .

$$(\nu^j)_i = \begin{cases} \nu_i & , \text{se } i \neq j; \\ -\nu_j & , \text{se } i = j. \end{cases}$$

2.1 Tipos de passeios aleatórios homogêneos:

2.1.1 Passeio homogêneo preguiçoso $\sigma(t)$

Seja $\nu \in H_N$ e $\sigma(0) = \nu$, $\sigma(t)$ é uma evolução estocástica em relação a um tempo discreto, onde para cada t escolhemos $i \in \{1, \dots, N\}$ com probabilidade $\frac{1}{N}$ e escolheremos em seguida o spin $\sigma_i = +1$ com probabilidade $\frac{1}{2}$. Podemos interpretar o passeio homogêneo como a sequência de duas variáveis aleatórias $I(t)$ e $U(t)$, definidas em $(\Omega_N, \mathcal{F}_N, \mathbb{P}_N)$, sendo $I(t) \in \{1, \dots, N\}$ independente e $\forall k \in \{1, \dots, N\}; \mathbb{P}_N(I(t) = k) = \frac{1}{N}$ e $U(t) \in [0, 1]$ independente e $\forall u \in [0, 1]; \mathbb{P}_N(U(t) < u) = u$, ou seja, identicamente distribuída uniformemente em $[0, 1]$.

Assim,

$$(\sigma_j(t)) = \begin{cases} \sigma(t-1) & , \text{se } I(t) \neq j; \\ +1 & , \text{se } I(t) = j; U(t) < \frac{1}{2}; \\ -1 & , \text{se } I(t) = j; U(t) \geq \frac{1}{2}. \end{cases}$$

2.1.2 Passeio homogêneo não preguiçoso $\xi(t)$

Seja $\xi(0) = \nu \in H_N$ e $\xi(t)$ um passeio aleatório no H_N definido em $(\Omega_0, \mathcal{F}_0, \mathbb{P}_0)$ com probabilidade de transição $\mathbb{P}(\xi(t+1) = \nu^i | \xi(t) = \nu) = \frac{1}{N}$ para todo $k \geq 1$, $i \in \{1, \dots, N\}$. Perceba que $\mathbb{P}(\xi(t+1) = \nu | \xi(t) = \nu) = 0$, pois $\sum_i \mathbb{P}(\xi(t+1) = \nu^i | \xi(t) = \nu) = \left(N \cdot \frac{1}{N}\right) = 1$, ou seja, a probabilidade dele mudar alguma entrada/spin 100%.

Agora vamos introduzir algumas notações básicas para não ocorrer nenhum tipo de ambiguidade.

Notações

σ^- é o passeio homogêneo com configuração inicial $\sigma^-(0) = (-1, \dots, -1)$.

σ^+ é o passeio homogêneo com configuração inicial $\sigma^+(0) = (+1, \dots, +1)$.

σ^ν é o passeio homogêneo com configuração inicial $\sigma^\nu(0) = \nu, \nu \in H_N$.

ξ^- é o passeio homogêneo com configuração inicial $\xi^-(0) = (-1, \dots, -1)$.

ξ^+ é o passeio homogêneo com configuração inicial $\xi^+(0) = (+1, \dots, +1)$.

ξ^ν é o passeio homogêneo com configuração inicial $\xi^\nu(0) = \nu; \nu \in H_N$.

$t_N^- := \inf\{t > 0 : \sigma^+(t) = \sigma^-(t)\}$: Tempo de parada/encontro.

$t_N^{\nu, \zeta} := \inf\{t > 0 : \sigma^\nu(t) = \sigma^\zeta(t)\}$: Tempo de parada/encontro.

$D_N(t) := \left| \frac{K^+(t) - P^-(t)}{2N} \right|$ tal que K, P é um passeio preguiçoso ou não preguiçoso:

É a distância no tempo t .

$D_N^{\nu, \zeta}(t) := \left| \frac{K^\nu(t) - P^\zeta(t)}{2N} \right|$ tal que K, P é um passeio preguiçoso ou não preguiçoso:

É a distância no tempo t .

$V[0, N^\gamma] := \{\sigma^+(0), \dots, \sigma^+(N^\gamma)\}$.

O Teorema 2.1 nos dá uma estimativa do crescimento do tempo que leva para dois pontos do hipercubo se encontrarem quando $N \rightarrow \infty$.

Teorema 2.1. *Seja $t_N^- = \inf(t > 0 : \sigma^+(t) = \sigma^-(t))$. Então,*

$$\lim_{N \rightarrow \infty} \mathbb{P} \left(\left| \frac{t_N^-}{N \log N} - 1 \right| > \varepsilon \right) = 0, \forall \varepsilon > 0.$$

Demonstração do Teorema 2.1. Para provar o teorema é suficiente mostrar que

$$\lim_{N \rightarrow \infty} \mathbb{P} \left(\frac{t_N^-}{N \log N} \right) = 1.$$

Seja $D_N(t) = \frac{1}{2N} \sum_{i=1}^N |\sigma_i^+(t) - \sigma_i^-(t)|$ a distância no instante n entre σ^+ e σ^- .

Pela evolução de $\sigma(t)$ temos que $D_N(t)$ é uma cadeia de Markov em $\{0, \frac{1}{N}, \dots, \frac{N-1}{N}, 1\}$ sendo a probabilidade de transição dada por:

$$\mathbb{P}_{xy} = \begin{cases} 1 - x & , \text{ se } y = x, \\ x & , \text{ se } y = x - \frac{1}{N}, \\ 0 & , \text{ c.c.} \end{cases}$$

Definimos $t_N^- = \sum_{k=1}^N \lambda_k$, onde $\lambda_1 = 1$ e λ_k são variáveis aleatórias de geométricas de parâmetros $p_k = 1 - \frac{k-1}{N}$. λ_k são o menor tempo que o processo $D_N(t)$ demora para sair de $1 - \frac{k-1}{N}$ para $1 - \frac{k}{N}$.

Vamos ver a esperança:

$$\begin{aligned} \mathbb{E}(\lambda_k) &= \sum_n^{\infty} \mathbb{P}(\lambda_k = n) \cdot n, \\ &= 1 \cdot p_k + 2 \cdot p_k(1 - p_k) + 3 \cdot p_k(1 - p_k)^2 + \dots \end{aligned}$$

Como $\mathbb{E}(\lambda_k) \cdot (1 - p_k) = 1 \cdot p_k(1 - p_k) + 2 \cdot p_k(1 - p_k)^2 + 3 \cdot p_k(1 - p_k)^3 + \dots$

$$\begin{aligned} \mathbb{E}(\lambda_k) - (1 - p_k) \cdot \mathbb{E}(\lambda_k) &= p_k + p_k \cdot (1 - p_k) + p_k \cdot (1 - p_k)^2 + \dots, \\ p_k \mathbb{E}(\lambda_k) &= p_k(1 + (1 - p_k) + (1 - p_k)^2 + \dots), \\ \mathbb{E}(\lambda_k) &= (1 + (1 - p_k) + (1 - p_k)^2 + \dots), \\ &= \frac{1}{1 - (1 - p_k)} = \frac{1}{p_k} = \frac{N}{N + 1 - k}. \end{aligned}$$

Agora vamos observar a variância:

$$\text{Var}(\lambda_k) = \mathbb{E}(\lambda_k - \mathbb{E}(\lambda_k))^2 = \mathbb{E}(\lambda_k^2) - \mathbb{E}(\lambda_k)^2.$$

Vamos obter $\mathbb{E}(\lambda^2)$:

$$\mathbb{E}(\lambda_k^2) = \sum_x^{\infty} x^2 \cdot \mathbb{P}(\lambda_k = x) = \sum_x^{\infty} x^2 \cdot (1 - p_k) p_k^{x-1},$$

$$= \sum_x^\infty x^2 q^{x-1} p_k = p_k \sum_x^\infty x \frac{d}{dq_k} q_k^x.$$

Sendo $q_k = (1 - p_k)$.

$$\begin{aligned} \mathbb{E}(\lambda_k^2) &= p_k \frac{d}{dq_k} \cdot q \sum_x^\infty x \cdot q_k^{x-1} = p_k \frac{d}{dq_k} \cdot q \sum_x^\infty \frac{d}{dq_k} q_k^x, \\ &= p_k \frac{d}{dq_k} \cdot q \cdot \frac{d}{dq_k} \sum_x^\infty q_k^x = p_k \frac{d}{dq_k} \cdot q \cdot \frac{d}{dq_k} \cdot \left(\frac{q_k}{1 - q_k} \right), \\ &= p_k \left(\frac{1 + q_k}{(1 - q_k)^2} \right) = \frac{2 - p_k}{p_k^2}. \end{aligned}$$

Assim, $\text{Var}(\lambda_k) = \frac{2-p_k}{p_k^2} - \frac{1}{p_k^2} = \frac{1-p_k}{p_k^2}$. Substituindo $p_k = 1 - \frac{k-1}{N}$, temos $\text{Var} = \frac{N(k-1)}{(N+1-k)}$.

Logo,

$$\begin{aligned} \mathbb{E}(t_N^-) &= \mathbb{E} \left(\sum_{k=0}^N \lambda_k \right) = \sum_{k=0}^N \frac{N}{N+1-k}, \\ &= N \sum_{k=0}^N \frac{1}{N+1-k} = N \sum_{k=1}^N \frac{1}{k}. \end{aligned}$$

Como $\int_1^N \frac{1}{x} dx = \log N$, então $N \log(N-1) \leq \mathbb{E}(\lambda_k) = N \sum_{k=1}^N \frac{1}{k} \leq N \log(N)$.

Quando $n \rightarrow \infty$, $\mathbb{E}(t_N^-) \sim N \log(N)$. Logo, pela desigualdade de Tchebyshev:

$$\begin{aligned} \mathbb{P}(t_N^- - \mathbb{E}(t_N^-) | \varepsilon \cdot \mathbb{E}(t_N^-)) &\leq \frac{\text{Var}(t_N^-)}{\varepsilon^2 \cdot \mathbb{E}(t_N^-)} = \frac{\sum_{k=1}^N \frac{N(k-1)}{(N-K+1)^2}}{\varepsilon^2 \left(\sum_{k=1}^N \frac{N}{N-K+1} \right)^2}, \\ &= \frac{N}{\varepsilon^2 \cdot N^2} \cdot \frac{\sum_{k=1}^N \frac{(k-1)}{(N-k+1)^2}}{\left(\sum_{k=1}^N \frac{1}{N-k+1} \right)^2}. \end{aligned} \quad (2.1)$$

Sendo $N-1$ o maior numero dos termos da soma $\sum_{k=1}^N (k-1)$, então (2.1) é menor ou igual a

$$\frac{N(N-1)}{\varepsilon^2 \cdot N^2} \cdot \frac{\sum_{k=1}^{N-1} \frac{1}{k^2}}{\left(\sum_{k=1}^N \frac{1}{N-k+1} \right)^2} \leq \frac{N(N-1)}{\varepsilon^2 \cdot N^2} \cdot \frac{1 + \sum_{k=2}^{N-1} \frac{1}{k^2 - 1}}{(\log N)^2},$$

$$\leq \frac{N(N-1)}{\varepsilon^2 \cdot N^2} \cdot \frac{1 + \frac{3}{4} - \frac{2N+1}{2N(N+1)}}{(\log N)^2}.$$

Quando $N \rightarrow \infty$,

$$\lim_{N \rightarrow \infty} \frac{N(N-1)}{\varepsilon^2 \cdot N^2} \cdot \frac{1 + \frac{3}{4} - \frac{2N+1}{2N(N+1)}}{(\log N)^2} = 0.$$

Portanto, $\lim_{N \rightarrow \infty} \mathbb{P} \left(\left| \frac{t_N^-}{\mathbb{E}(t_N^-)} - 1 \right| > \varepsilon \right) = 0$. □

Corolário 2.1. *Sejam σ^ν e σ^ζ passeios homogêneos em H_N construídos simultaneamente, com configurações iniciais ν, ζ . Suponha para $0 \leq f \leq 1$, que $D_N(0) = \frac{[N \cdot f]}{N}$.*

Então, $\lim_{N \rightarrow \infty} \mathbb{P}(\sigma^\nu(t(N)) \neq \sigma^\zeta(t(N))) = 0$, para qualquer $t(N)$ com $\lim_{N \rightarrow \infty} \frac{t(N)}{N \log N} = \infty$.

Demonstração Corolário 2.1. Primeiros notamos que $t_N^- = \inf(t > 0 : \{I(1), \dots, I(t)\} = \{1, \dots, N\})$. Assim,

$$\mathbb{P}(\sigma^\nu(t(N)) \neq \sigma^\zeta(t(N))) \leq \mathbb{P}(t_N^- > t(N)) \leq \frac{N(\log N + 1)}{t(N)}.$$

Portanto, por hipótese temos que

$$\lim_{N \rightarrow \infty} \mathbb{P}(\sigma^\nu(t(N)) \neq \sigma^\zeta(t(N))) = 0.$$

□

Corolário 2.2. *Seja $t(N)$ com $\lim_{N \rightarrow \infty} \frac{t(N)}{N \log N} = \infty$. Então,*

$$\lim_{N \rightarrow \infty} \left| \mathbb{P}(\sigma^+(t(N)) = \zeta) - \frac{1}{2^N} \right| = 0,$$

para todo $\zeta \in H_N$.

Demonstração do corolário 2.2. Vamos primeiro mostrar que μ é uma medida invariantes com respeito à evolução do passeio homogêneo.

$$\begin{aligned} \mathbb{P}(x_1 = \zeta) &= \sum_{\nu \in H_N} \mathbb{P}(x_1 = \zeta \mid x_0 = \nu) \cdot \frac{1}{2^N}, \\ &= \mathbb{P}(x_1 = \zeta \mid x_0 = \zeta) \cdot \frac{1}{2^N} + \sum_{i=1}^N \mathbb{P}(x_1 = \zeta \mid x_0 = \zeta^i) \cdot \frac{1}{2^N}, \\ &= \frac{1}{2} \cdot \frac{1}{2^N} + \frac{1}{2} \cdot \frac{1}{N} \cdot \frac{1}{2^N} \cdot N = \frac{1}{2^{N+1}} + \frac{1}{2^{N+1}} = \frac{1}{2^N} = \mathbb{P}(x_1 = \nu). \end{aligned}$$

Assim,

$$\begin{aligned}
\left| \mathbb{P}(\sigma^+(t(N)) = \zeta) - \frac{1}{2^N} \right| &= \left| \mathbb{P}(\sigma^+(t(N)) = \zeta) - \sum_{\nu \in H_N} \mu(\nu) \mathbb{P}((\sigma^\nu = \zeta)) \right|, \\
&\leq \sum_{\nu \in H_N} \mu(\nu) \left| \mathbb{P}(\sigma^+(t(N)) = \zeta) - \mathbb{P}(\sigma^\nu(t(N)) = \zeta) \right|, \\
&\leq \sum_{\nu \in H_N} \sup(\mathbb{P}(\sigma^+(t(N)) \neq \sigma^\nu(t(N)))) = 0.
\end{aligned}$$

A última igualdade é análoga ao corolário anterior. $\square$

Obs: Para um movimento não preguiçoso, $\xi(t)$, talvez não seja possível ocorrer um acoplamento. Se duas configurações iniciais, ν e ζ , diferem em um número ímpar de coordenadas e tem esse tipo de movimentação, nunca poderá haver um acoplamento, pois a distância mínima é, $D_N(t) \geq \frac{1}{N}$.

Demonstração. Seja $\nu, \phi \in H_N$ tal que $D_N^{\nu, \phi}(0) = n$ sendo n um número ímpar. Vamos observar 3 situações possíveis no passeio:

- 1) Se $(\nu^i) = (\phi^i)$, então $(n^i)_i = (\phi^i)_i$;
- 2) Se $(\nu^i) \neq (\phi^i)$, então $(n^i)_i \neq (\phi^i)_i$;
- 3) Se $(\nu^i) = (\phi^i)$, então $(n^i)_i \neq (\phi^i)_j$ sendo $i \neq j$.

Se ocorrer alguns desses casos, a distância das nossas cadeias, ou se mantém a mesma ou afastam-se, mas nunca se aproximam. Logo, supondo que por ventura só alteramos as entradas que são distintas ao longo do tempo. Como a cada passo, $I_\nu(1) = i$ e $I_\phi(1) = j$ tal que $i \neq j$, então $D_N^{\nu, \phi}(1) = n - 2$ já que estamos considerando sempre o melhor dos casos, que seria mudar duas entradas diferentes. Repetindo isso várias vezes, temos que existe um t' tal que $D_N^{\nu, \phi}(t') = 1$, pois n é ímpar e a cada tempo diminuimos duas posições. Assim, caímos no caso 3), ou seja, $D_N^{\nu, \phi}(t) \leq \frac{1}{N}$. $\square$

O Teorema 2.2 nos diz que é certo que $\xi(t)$ retorna a uma posição visitada quando $N \rightarrow \infty$, além de nos mostrar que essa posição de retorno é do tipo $\xi(i)$ e $\xi(j) \forall i, j \leq k + 1$, e $\xi(k + 2) = \xi(k)$ para algum k .

Teorema 2.2. *Seja $S_N = \inf(k > 0 : \xi(k) \in \{\xi(0), \xi(1), \dots, \xi(k - 1)\})$ e $\Gamma_1 = \inf(k > 0 : I(k) = I(k - 1))$. Então, $\lim_{N \rightarrow \infty} \mathbb{P}[S_N = \Gamma_1] = 1$.*

Para a demonstração desse teorema vamos adotar algumas definição e notações:

- 1) Seja I uma variável que escolhe uma coordenada i de um $\nu \in H_N$. Vamos denotar I avaliado no tempo k como I_k .
- 2) $J_1 = \{(I_1, I_2) \in \{1, 2, \dots, N\}^2 : I_1 = I_2\}$.
- 3) $J_l = \{(I_1, I_2, \dots, I_{2l}) \in \{1, 2, \dots, N\}^{2l} : \sum_{k=1}^{2l} 1_{\{i=I_k\}} \in \{0, 2, 4, \dots, 2l\} \forall i \in \{1, 2, \dots, N\} \text{ e } (I_1, I_2, \dots, I_{2k}) \notin J_k \forall k \in \{1, 2, \dots, l-1\}\}$.
- 4) Definimos um grupo de $i \in \{1, 2, \dots, N\}$ do vetor $(I_1, I_2, \dots, I_{2l}) \in J_l$ como $\{k \in \{1, 2, \dots, 2l-1, 2l\} : i = I(k)\}$.

Uma forma de pensar nos vetores desses J 's é ver eles como caminho na forma de laço.

Proposição 2.1. Para $l \geq 3$

$$\mathbb{P}(I_1, \dots, I_{2l}) \in J_l \leq \frac{8}{N^3}.$$

Demonstração da Proposição. 2.1 Sabemos que $\mathbb{P}(I_1, \dots, I_{2l}) \in J_l = \frac{|J_l|}{N^{2l}}$. Fazendo uma estimativa superior temos que $|J_l| \leq 2N^{2l-2}$, pois sendo $(I_1, \dots, I_{2l}) \in J_l$, então $(I_1, \dots, I_{2l-2}) \notin J_{l-1}$, evitando a recursividade, podemos supor que $\exists i' \in \{1, \dots, N\}$ tal que $\sum_{k=1}^{2l-2} 1_{\{i'=I_k\}}$ é ímpar, como o tamanho do vetor é par, então deve $\exists i'' \neq i'$ tal que $\sum_{k=1}^{2l-2} 1_{\{i''=I_k\}}$ é ímpar. Logo, como $(I_1, I_2, \dots, I_{2l-1}, I_{2l}) \in J_l$, então $\sum_{k=1}^{2l} 1_{\{i'=I_k\}}$ e $\sum_{k=1}^{2l} 1_{\{i''=I_k\}}$ são somas pares, ou seja, os dois últimos índices são determinados pelos i' e i'' . Como i' e i'' são diferentes, então podemos permutá-los, assim $|J_l| \leq 2N^{2l-2}$. Podemos dividir J_l em dois conjuntos disjuntos, J_l'' e J_l' , onde J_l'' é o conjunto onde nas três últimas entradas existe duas iguais, e J_l' é o conjunto onde as três últimas entradas são distintas. Vamos achar uma estimativa superior para esse conjuntos. Em J_l' como a entrada $2l-2$ é distinta das duas últimas e sabemos que temos dois blocos ímpares distintos que determinam as duas últimas entradas, então o bloco de I_{2l-2} no subvetor $(I_1, I_2, \dots, I_{2l-3})$ é ímpar, pois se fosse o contrário, a soma $\sum_{k=1}^{2l} 1_{\{I_{2l-2}=I_k\}}$ seria ímpar. Logo, a entrada $2l-2$ é determinado por um terceiro bloco ímpar. Logo, $|J_l'| \leq 3!N^{2l-3}$. No conjunto J_l'' perceba que como $I_{2l-1} \neq I_{2l}$, então existem somente dois casos $I_{2l-2} = I_{2l}$ e $I_{2l-1} = I_{2l-2}$. Sem perda de generalidade, vamos supor que é verdade $I_{2l-1} \neq I_{2l}$. Como ambas as duas coordenadas estão determinadas pelo mesmo bloco, então podemos lidar com esse vetor de $2l$ entradas como se fosse de $2l-2$ entradas. Assim, $|J_l''| \leq N \cdot |J_{l-1}''|$, pois as coordenada

repetida pode ter combinação de N valores. Portanto,

$$\frac{|J_l|}{N^{2l}} = \frac{|J'_l|}{N^{2l}} + \frac{|J''_l|}{N^{2l}} \leq \frac{3!N^{2l-3}}{N^{2l}} + \frac{N \cdot 2N^{2l-4}}{N^{2l}} = \frac{8}{N^3}.$$

□

Capítulo 3

Abordagem Potencial para Metaestabilidade

Vamos denotar $E_N, N \geq 1$, o conjunto de estados de uma malha quadrada de largura N e dimensão d , como representado abaixo. Os estados (pontos ou configurações) de E_N é representado por η, ξ, ζ .




Figura 3.1: Malha $\Lambda_N = \{0, \dots, N\}^d$ com um elemento de E_N destacado por azul.

Se considerarmos uma evolução dos estados podemos indexar E_N para cada tempo, $E_{t,N}$. Para isso, consideremos que para $E_{t,N}$, temos um sequencia de malhas Λ_N onde para cada par de malhas vizinhas temos somente um ponto em comum, como a figura a abaixo.




Figura 3.2: Um caminhar aleatório com dois estados

Assim podemos definir E_N como a união dos $E_{t,N}$, ou seja, podemos pensar E_N como os estados de uma partícula de $0 \leq t \leq p$ sendo p um inteiro. Vamos denotar $\eta_N(t)$ uma cadeia de Markov de tempo contínuo em E_N tal que o pulo de $\eta \in E_{t,N}$ para seus vértices vizinhos é uniforme, e para mudar seu estado espera um tempo exponencial. Perceba que essa cadeia de Markov é irreduzível.

Dizemos que o grau de $\eta \in E_N$, $\deg(\eta)$, é quantidade de vizinhos. Assim conseguimos definir uma medida de probabilidade

$$\pi_N(\eta) = \frac{\deg(\eta)}{Z_N}$$

onde $Z_N = \sum_{\xi \in E_N} \deg(\xi)$. Então, como sabemos que π_N satisfaz a *Equação de balanço*, então a distribuição é estacionária e única. Vamos estudar o exemplo *Coarse-grained-model*. Vamos denotar $\Gamma_N : E_N \rightarrow \{0, 1, 2, 3\}$ a projeção de uma partícula no seu tempo,

$$\Gamma_N(\eta) = \sum_{k=0}^3 k \chi_{E_{k,N}}(\eta).$$

Perceba que não tem problema nas intersecções dos quadrados, pois cada quadrado irá ter $(N^d - 1)$ vértices. A função da evolução assintótica do *Coarse-grained-model*

$$\mathbf{Y}_N(t) = \Gamma_N(\eta_N(t))$$

é um passeio aleatório entre cubos discretos. Vamos denotar $z_N(t)$ o andar aleatório simétrico, de tempo contínuo em Λ^N , ou seja, o processo η_N restrito a Λ_N , ademais

seja $\pi_N(\Lambda_N)$ a medida estacionária em Λ_N . Pela proposição??, temos que a ordem com que $z_N(t)$ converge para uma transição estacionária é de N^2 , além disso o tempo estimado de um ponto x para outro que dista N é da ordem $\alpha_N = N^2 \log N$ em dimensão $d = 2$ e $\alpha_N = N^d$ em dimensão $d \geq 3$.

Assumindo que iniciamos no centro de $\mathbb{Z}_N^d$. Definamos também B como o conjunto dos pontos de intersecção, $E_{j,N} \cap E_{i,N}$ para todo $j \neq i$. Logo, seja

$$H_B^N = \inf\{t \geq 0 : \eta_N(t) \in B\}.$$

Como a ordem de H_B^N é maior que a ordem de convergência da cadeia para sua estacionária, então dizemos que ela termaliza ou equilibra antes de chegar nas quinas compartilhadas. Assim podemos intuir que quanto mais perto de B mais nossa "partícula" esquece do caminho que veio, como consequência a probabilidade da partícula mudar de estado se a próxima de $\frac{1}{2}$. Quando a partícula termaliza, ela passeia em $E_{j,N}$ em um tempo de ordem α_N até chegar em ponto de intersecção, que denominamos de ξ . Para evitar essa pergunta, podemos definir uma sequência $(l_N : N \geq 1)$ de números reais tais que $l_N \rightarrow \infty$ e $\frac{l_N}{N} \rightarrow 0$. Assim criamos V_N , o conjunto dos pontos que distam até l_N de ξ . Após alcançar ξ , nosso caminho aleatório faz um pequeno percurso em V_N . Como escolhemos uma boa vizinhança, o que poderia acontecer, de a partícula voltar para ξ antes de sair de V_N , certamente não acontecerá, pois a ordem da partícula escapar de V_N é menor que a ordem do tempo de encontro. Para $d = 2$,

$$\frac{\ell_N^2}{\alpha_N} = \frac{\ell_N^2}{N^2 \log N} = \left(\frac{t}{N}\right)^2 \cdot \frac{1}{\log N} \rightarrow 0 \cdot 0 = 0.$$

Para $d \geq 3$,

$$\frac{\ell_N^2}{\alpha_N} = \frac{\ell_N^2}{N^2} = \left(\frac{t}{N}\right)^2 \rightarrow 0.$$

Nesse vai e volta ao ξ dentro do V_N que pode está ocorrendo em $E_{i,N}$ ou $E_{i\pm 1,N}$, ao alcançar um tempo de ordem l^2 , a partícula consegue escapar do V_N . Perceba que esse tempo é irrisório comparado ao tempo de encontro nas quinas, α_N . Desde que esse tempo seja muito maior do que o tempo de equilíbrio, temos a repetição do processo novamente.

3.1 Apêndice A

Como base para entendermos o escopo deste trabalho, foi criado algumas simulações usando a linguagem Python, fazendo uso das bibliotecas *matplotlib*,

Pandas e Numpy.




Figura 3.3: Acoplamento de dois caminhar aleatório com N fixo

Referências Bibliográficas

- [Kipnis-Landim] C. Kipnis and C. Landim, *Scaling Limits of Interacting Particle Systems* , Springer-Verlag Berlin Heidelberg, (1999).
- [Tsallis] Tsallis, Constantino , *Introduction to Nonextensive Statistical Mechanics*, New York, (2009).
- [Shannon] Shannon, C. E. , *A Mathematical Theory of Communication* , The Bell System Technical Journal, (1948).
- [Khinchin] Khinchin, A. I. , *Mathematical Foundations of Information Theory* , New York, (1957).
- [Durrett] Durrett, Richard. , *Probability, Theory and Examples* , Brooks/Cole, (2005).
- [Boucheron-Lugosi-Massart] S. Boucheron, G. Lugosi and P. Massart, *Concentration Inequalities* , Oxford, (2013).
- [Norris] Norris, J.R. , *Markov Chains* , Cambridge, (1997).

Universidade Federal da Bahia-UFBA
Instituto de Matemática / Colegiado da Pós-Graduação em Matemática

Av. Adhemar de Barros, s/n, Campus de Ondina, Salvador-BA
CEP: 40170 -110
www.pgmat.ufba.br